Mémoire présenté le :

pour l'obtention du Diplôme Universitaire d'actuariat de l'ISFA et l'admission à l'Institut des Actuaires

Par : Gaylord LEGRIS

Titre : Analyse de Sensibilités sur des Portefeuilles de Passifs en Assurance Vie selon les indicateurs Solvabilité 2 : Approche par Générations et Agrégations des portefeuilles

Confidentialité : ☒ NON ☐ (Durée : ☐ 1 an ☐ 2 ans)

Les signataires s'engagent à respecter la confidentialité indiquée ci-dessus

Membres présents du jury de l'Institut des Actuaires

. . . . . .

. . . . . .

. . . . . .

Membres présents du jury de l'ISFA

. . . . . .

. . . . . .

. . . . . .

Signature

Entreprise :
Nom :

Signature :

Directeur de mémoire en entreprise :
Nom :

Signature :

Invité :
Nom :

Signature :

Autorisation de publication et de mise en ligne sur un site de diffusion de documents actuariels *(après expiration de l'éventuel délai de confidentialité)*

Signature du responsable entreprise

Signature du candidat

Table des matières

Résumé **iii**

Abstract **iv**

Remerciements **v**

Synthèse **vi**

Synthesis **vii**

Introduction **1**

1 Contexte réglementaire et modélisation en assurance vie **3**
1.1 Les spécificités des produits d'assurance vie épargne 4
1.2 Le cadre prudentiel Solvabilité II 6
1.3 Les Générateurs de Scénarios Économiques (GSE) 10
1.4 La représentation du passif : le concept de *Model Point* 13
1.5 Gestion actif-passif et architecture du modèle de projection 15

2 Construction d'un générateur de portefeuilles de passifs **20**
2.1 Objectifs stratégiques et contraintes techniques 21
2.2 Méthodologie de génération et modélisation statistique 23
2.3 Présentation du portefeuille de référence généré 41

3 Présentation des méthodes d'agrégation candidates **49**
3.1 Les approches déterministes : Le standard de marché 50
3.2 Les approches statistiques spatiales (Apprentissage non supervisé) 54
3.3 L'approche par segmentation supervisée 65
3.4 Les approches dynamiques basées sur l'écoulement des flux 67
3.5 Conclusion 70

4 Protocole d'analyse et résultats de l'agrégation **72**
4.1 Définition du protocole de test comparatif 73
4.2 Analyse comparative et choix de la méthode optimale 75
4.3 A faire 77

5 Conclusion **79**

Conclusion **80**
5.1 Résumé des résultats 80
5.2 Perspectives d'amélioration 80
5.3 Conclusion Générale et Perspectives 81

Annexes **83**

Bibliographie **88**

Résumé

Petit résumé en français de mon mémoire ?

Abstract

It's a brief sum up in english !

Remerciements

Pour la réalisation de ce mémoire, je tiens à adresser mes remerciements à toutes les personnes qui ont contribué de près ou de loin à son élaboration. Que ce soit au travail avec Lionel Aldeberd qui m'a appris énormément, Lucas Blancheton qui a toujours été là pour m'aiguiller dans mes choix. Merci à Luc pour les relectures et à tous mes collègues stagiaires et alternants, Antoine, Cindy, Eleonore, Lucile, Malak, Manon, Nicolas, Tanguy et Titouan pour leur bonne humeur ! J'ai vraiment passé des très chouettes moments à vos côtés !

Synthèse

Un long résumé en français de mon mémoire

Synthesis

Un long résumé en anglais de mon mémoire

Introduction

Confirmant son statut de placement privilégié des français, l'assurance vie a vu son encours (provisions mathématiques *plus* provisions pour participation aux bénéfices) atteindre 1 986 milliards d'euros à fin 2024 (France Assureurs) [1]. Son attractivité dans un contexte économique incertain est soulignée par une collecte nette de +28,5 milliards d'euros, alimentée par une forte hausse des cotisations (+14,7 %). Cette dynamique globale masque toutefois une réorientation marquée des flux : alors que les supports en euros enregistrent une décollecte nette de 4,7 milliards d'euros, les unités de compte captent l'essentiel des nouveaux versements (+33,2 milliards d'euros). Conjuguée à un recul global des prestations versées aux assurés (-3,1 % tous supports confondus), cette situation place la gestion actif-passif (ALM) au cœur des enjeux stratégiques pour les assureurs. Ceux-ci doivent piloter leur résultats tout en maintenant l'équilibre entre sécurité et rendement pour les épargnants.

Le secteur de l'assurance vie en France est ainsi confronté à un besoin important de pilotage via la gestion actif-passif. Pour cela, les assureurs s'appuient sur l'utilisation de modèles ALM. Ces modèles simulent l'impact de différentes stratégies ce qui nécessite cependant un grand nombre de projections stochastiques, engendrant une contrainte opérationnelle majeure : le temps de calcul. Cette contrainte limite non seulement la capacité à explorer en profondeur l'ensemble des risques et des opportunités, mais freine également l'agilité stratégique et la réactivité des prises de décision. Face à ce compromis nécessaire entre rigueur réglementaire et contraintes opérationnelles, ce mémoire soulève la problématique suivante : comment concilier la rapidité d'exécution des calculs avec la fidélité des indicateurs de risque ?

Ce mémoire propose d'étudier l'impact des techniques d'agrégation du passif, notamment par la création de *model points*, qui consiste en une représentation simplifiée des contrats d'assurance. L'enjeu est de déterminer si cette modélisation simplifiée des portefeuilles de contrats peut constituer une solution fiable pour le pilotage stratégique, et d'évaluer sous quelles conditions une telle simplification est valide sans masquer des dynamiques de risque essentielles au pilotage de l'entreprise.

Pour répondre à cette problématique, ce mémoire adoptera une double approche. Premièrement, il s'agira de développer un générateur de portefeuilles de passif puis le reste de l'analyse portera sur les effets de l'agrégation sur un portefeuille représentatif du marché français. L'objectif est de comprendre comment les risques évoluent à travers l'agrégation. Pour cela, plusieurs méthodes et approches seront testées et comparées. Le critère de sélection de la méthode la plus pertinente reposera sur un double objectif : minimiser l'écart sur des indicateurs clés de la norme Solvabilité II, optimiser la rapidité des calculs en atteignant le plus haut niveau d'agrégation possible. Une fois la méthode cible sélectionnée, une analyse approfondie de sensibilités sera menée sur le portefeuille avant et après agrégation. L'impact de

chocs économiques sera ainsi évalué à travers deux métriques centrales : le *Best Estimate* (BE) et le *Solvency Capital Requirement* (SCR). Ces métriques permettront de mesurer rigoureusement comment l'agrégation modifie la perception du risque et la valeur économique du portefeuille. A REVOIR QUAND J'AI FINI POUR METTRE LA METHODO EXACTE

Ce mémoire s'articulera en cinq temps. La première partie posera le cadre conceptuel de l'étude en explorant le contexte réglementaire de Solvabilité II utilisé dans ce mémoire, les produits d'epargne en assurance vie et les fondements des Générateurs de Scénarios Économiques (GSE) en univers risque neutre. Après l'explication du socle théorique, la deuxième partie abordera les principes de la Gestion Actif-Passif, en détaillant l'architecture du modèle de projection qui servira de base aux travaux de ce mémoire. La troisième partie permettra de poser les bases de l'analyse, avec l'élaboration d'un générateur de portefeuilles de passifs réalistes destiné à produire les données synthétiques cohérentes. Le cœur méthodologique sera présenté en quatrième partie, à travers un protocole d'analyse comparant diverses méthodes d'agrégation afin de choisir celle qui sera utilisée. Enfin, la cinquième partie sera consacrée à l'interprétation des résultats d'agrégations sur des chocs économiques où, par le biais d'analyses de sensibilité approfondies, l'impact de la méthode d'agrégation retenue sur la mesure du risque sera quantifié, validant ou non la pertinence de l'approche adoptée.

Chapitre 1

Contexte réglementaire et modélisation en assurance vie

1.1 Les spécificités des produits d'assurance vie épargne

1.1.1 Principes fondamentaux du contrat d'assurance vie

L'assurance vie se définit comme une convention par laquelle un assureur s'engage, en contrepartie de la perception de primes, à verser un capital ou une rente lors de la survenance d'un événement incertain lié à la durée de la vie humaine. Cet aléa repose soit sur le décès de l'assuré avant une échéance déterminée, soit sur sa survie à cette même date. Comme tous les types d'assurance, cette mécanique s'appuie sur le principe fondamental d'inversion du cycle de production : la collecte des primes précède le règlement éventuel des prestations et la constatation définitive du coût de revient. Néanmoins, la spécificité inhérente à l'assurance vie réside dans l'horizon temporel particulièrement étendu de ces engagements. Cette dimension de long terme contraint structurellement l'assureur à capitaliser et à investir ces flux financiers sur les marchés de capitaux, afin d'être en mesure d'honorer ses passifs futurs.

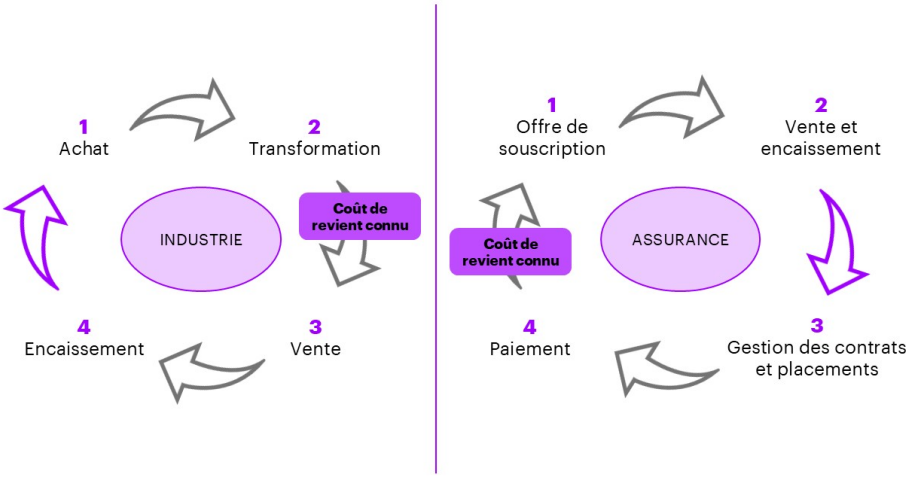

FIGURE 1.1 – Cycle de production inversé en assurance vie

La nature de ces engagements répond à des objectifs variés. Les contrats en cas de vie prévoient le versement d'un capital ou d'une rente à une échéance prévue si l'assuré est en vie ; ils sont typiquement utilisés pour se constituer un complément de retraite ou une épargne de précaution. À l'opposé, les contrats en cas de décès garantissent le versement d'un capital ou d'une rente au(x) bénéficiaire(s) désigné(s) au décès de l'assuré. Il existe également des contrats mixtes qui combinent ces deux garanties.

Le fonctionnement de ces contrats repose sur la capitalisation : les primes versées sont investies pour financer la propre couverture future de l'assuré. De par leur nature, ces engagements s'étendent sur de très longues périodes. Une caractéristique fondamentale de l'assurance vie française est sa liquidité. L'assuré dispose de la possibilité de récupérer son épargne à tout moment via un rachat, qui peut être partiel ou total. Cette faculté de rachat constitue une option dont la valeur et le risque doivent être finement gérés par l'assureur, car son exercice a un impact direct sur les besoins de liquidité du portefeuille. La fiscalité

joue un rôle incitatif majeur car les plus-values sont imposées plus lourdement si le rachat intervient avant la huitième année du contrat. Ceci encourage alors l'épargne de long terme.

La gestion de ces engagements de long terme amène l'assureur à proposer différentes modalités d'investissement. Celles-ci permettent de répartir le risque financier entre l'assuré et l'assureur, définissant ainsi le profil de rendement potentiel du contrat. Un contrat plus sûr aura des possibilités de rendements plus faible qu'un contrat risqué. L'épargne des assurés peut ainsi être investie sur deux principaux types de supports aux profils de risque distincts, qui peuvent être combinés au sein de différents types de contrats.

1.1.2 Les principaux supports d'investissement

L'épargne des assurés peut être investie sur deux principaux types de supports aux profils de risque distincts, les fonds en euros et les fonds en unités de compte (UC), qui peuvent être combinés au sein de contrats multisupports.

Le **fonds en euros** est le support historique et sécuritaire de l'assurance vie française. Le risque financier y est intégralement porté par l'assureur, qui s'appuie sur une politique d'investissement prudente, majoritairement orientée vers des actifs obligataires. La sécurité de ce support repose sur un ensemble de garanties contractuelles et réglementaires :

— **La garantie du capital :** Il s'agit de l'engagement contractuel principal de ce type de support. L'assureur garantit à tout moment le capital investi par l'épargnant. Ainsi, indépendamment de la volatilité des marchés financiers, la somme initialement versée, nette de frais, est intégralement préservée.

— **Le Taux Minimum Garanti (TMG) :** Plus courant aujourd'hui que le taux technique, le TMG est un taux de rendement minimal que l'assureur s'engage à verser pour l'année à venir. Il est fixé annuellement et permet à l'assureur d'ajuster sa politique de rendement.

— **L'effet cliquet :** Ce mécanisme assure que les intérêts générés chaque année sont définitivement acquis. Une fois distribués, ils s'ajoutent au capital garanti et produisent à leur tour des intérêts les années suivantes. Il est impossible de revenir sur les revalorisations passées.

— **La Participation aux Bénéfices (PB) :** L'assureur a l'obligation légale de redistribuer aux assurés au minimum 85% de ses bénéfices financiers et 90% de ses bénéfices techniques. Cette participation constitue la majeure partie du rendement annuel, au-delà du TMG. Pour lisser les performances, une partie de cette PB peut être mise en réserve dans une *Provision pour Participation aux Bénéfices* (PPB) que nous appelerons *Provision pour Participations aux Excedents* (PPE) dans la suite de ce mémoire. La PPE doit être reversée aux assurés dans un délai de huit ans au maximum pour les contrats d'épargne [1].

Les **unités de compte (UC)** offrent une exposition directe aux marchés financiers. Contrairement au fonds en euros, le risque d'investissement est entièrement porté par l'assuré. L'assureur ne garantit pas la

1. Pour les contrats retraite, ce délai passe à 15 ans.

valeur du capital, mais un nombre de parts d'actifs (OPCVM, actions, SCPI, etc.). La valeur de l'épargne fluctue ainsi en fonction des marchés, offrant un potentiel de rendement supérieur à long terme, mais exposant également à un risque de perte en capital. Pour l'assureur, la gestion de ce support est plus simple dans la mesure où il ne porte pas le risque d'investissement et n'octroie donc aucune garantie financière particulière.

Ces supports d'investissement s'articulent autour de deux grandes familles de contrats. D'une part, les contrats dits « monosupports » ne permettent d'investir que sur le fonds en euros. D'autre part, les contrats « multisupports », qui constituent aujourd'hui le standard du marché, offrent la possibilité de combiner un fonds en euros avec plusieurs types de supports en unités de compte.[2] Dans le cadre de cette étude, le portefeuille analysé se compose exclusivement de contrats multisupports, présentant une allocation représentative du marché français, soit approximativement 60 % en fonds en euros et 40 % en unités de compte.

	Ensemble		Euros		Unités de compte	
	En Md€	Var	En Md€	Var.	En Md€	Var
Cotisations	**174,9**	**14,70%**	**108,6**	**19,2%**	**66,3**	**8,1%**
Prestations	**146,4**	**-3,10%**	**113,3**	**-5,5%**	**33,1**	**6,4%**
Collecte nette	**28,5**	**27,1 Md€**	**-4,7**	**24,1 Md€**	**33,2**	**3 Md€**
Encours	**1985,8**	**3,90%**	**1398,6**	**1,4%**	**587,1**	**10,3%**
dont provisions mathématiques	1932,2	4,4%	1345	2%	587,1	10,3%
dont provision pour participation aux bénéfices	53,6	-11,1%	53,6	-11,1%	na.	na.

FIGURE 1.2 – Le marché de l'assurance vie en France en 2024 **(Sépérateur de milliers + réorg : EURO|UC|ENSEMBLE + Var. et non Var dans colonne Ensemble) + indiquer que Var c'est par rapport à 2023**

Ces contrats sont soumis à un ensemble de réglementations prudentielles visant à garantir la solvabilité des assureurs et la protection des assurés. La directive Solvabilité II encadre ces exigences à l'échelle européenne. La partie suivante détaille le cadre réglementaire de Solvabilité II, ses implications pour les assureurs vie, ainsi que les outils de modélisation stochastique utilisés pour répondre à ces exigences.

2. Il est intéressant de noter qu'un contrat intégralement investi en unités de compte est considéré techniquement comme un contrat multisupports, bien que cette configuration s'avère rare en pratique.

1.2 Le cadre prudentiel Solvabilité II

Entrée en vigueur le 1er janvier 2016, la directive Solvabilité II régit le cadre prudentiel de la quasi-totalité des assureurs et réassureurs de l'Union européenne. Son objectif primaire réside dans la protection optimale des assurés. Afin d'y parvenir, elle instaure un ensemble d'exigences et de bonnes pratiques visant à harmoniser le secteur et à garantir la capacité des compagnies à honorer leurs engagements en toutes circonstances. Ce référentiel s'appuie sur une approche économique et prospective, fondée sur une évaluation juste des risques et structurée autour de trois piliers. Seuls le premier pilier sera détaillé dans cette section, celui-ci s'avère le plus pertinent au regard des travaux de modélisation menés dans ce mémoire.

1.2.1 Le pilier 1 : exigences quantitatives et bilan prudentiel

Le Pilier 1 définit les exigences quantitatives, au cœur desquelles se trouve le bilan prudentiel. Il s'agit d'une vision économique du bilan comptable où les actifs et les passifs sont évalués de manière cohérente avec leur valeur de marché, c'est à dire de manière *market-consistent*. La structure de cette section suivra l'équation fondamentale du bilan prudentiel :

$$\text{Actifs} = \text{Provisions Techniques} + \text{Fonds Propres} \tag{1.1}$$

Chaque terme de cette équation sera détaillé successivement.

<table>
<tr><th colspan="3">BILAN ECONOMIQUE SOUS SOLVABILITE II</th></tr>
<tr><td rowspan="5">Actifs</td><td rowspan="3">Fonds propres</td><td>Capital excédentaire</td></tr>
<tr><td>SCR</td></tr>
<tr><td>MCR</td></tr>
<tr><td rowspan="2">Provisions techniques</td><td>Risk Margin</td></tr>
<tr><td>Best Estimate</td></tr>
</table>

FIGURE 1.3 – Bilan économique sous Solvabilité II (Mieux refléter la structure passif = actif) Modifier le graphique car la S1 et S2 mélangés

1.2.1.1 L'évaluation des Actifs à la valeur de marché

Le premier terme du Bilan, l'Actif, est évalué à sa valeur de marché (VM). Solvabilité II marque à cet égard une rupture fondamentale avec les normes prudentielles antérieures : il s'agit du premier référentiel à imposer ce concept de juste valeur, remplaçant ainsi l'approche traditionnelle fondée exclusivement sur la valeur comptable. Cette valorisation économique vise à refléter avec exactitude la valeur actuelle et

réelle des ressources mobilisables par l'assureur pour faire face à ses engagements. [3]

1.2.1.2 Les provisions techniques : Cœur de l'évaluation du passif

Les provisions techniques (PT) représentent la valeur des engagements de l'assureur envers ses assurés. La valeur des provisions techniques (PT) se décompose de la manière suivante [4] :

$$\text{PT} = \text{Best Estimate (BE)} + \text{Risk Margin (RM)} \tag{1.2}$$

La valorisation des provisions techniques, au cœur du bilan prudentiel, ne peut se contenter d'une vision unique et figée du futur. La présence d'options et de garanties dans les contrats d'épargne impose de distinguer deux approches complémentaires :

— **L'approche déterministe** (ou equivalent certain) est un outil de pilotage. Elle repose sur une projection unique des variables économiques. Bien qu'insuffisante pour la valorisation prudentielle, elle demeure un outil fondamental pour l'élaboration du *business plan* et la communication d'un scénario central. Sa limite principale est son incapacité à valoriser les risques asymétriques.

— **L'approche stochastique** est un outil de valorisation. Elle explore un grand nombre de futurs possibles à l'aide d'un **GSE**. Cet outil produit des milliers de simulations cohérentes des marchés financiers. La valeur d'un indicateur est alors obtenue en calculant la moyenne des résultats sur l'ensemble de ces scénarios (méthode de Monte-Carlo). Cette exploration est indispensable pour quantifier le coût réel des garanties optionnelles (TMG, etc.).

La différence de valeur entre ces deux approches est capturée par le concept de **TVOG (*Time Value of Options and Guarantees*)**. En imposant une approche stochastique, Solvabilité II assure une valorisation *market-consistent* des engagements.

Le **Best Estimate (BE)**, ou *Best Estimate Liability* (BEL), représente la meilleure estimation de la valeur actuelle des flux de trésorerie futurs liés aux engagements d'assurance. Son calcul est réalisé sur un horizon long (40-60 ans) en *run-off* (portefeuille en extinction, pas de nouvelles souscriptions). Il est obtenu par la moyenne des flux actualisés sur un grand nombre de simulations économiques stochastiques en univers risque neutre :

$$BEL = \mathbb{E}^{\mathbb{Q}}\left[\sum_{j=1}^{T} CF(j) \cdot e^{-\int_0^j r(s)ds}\right] \approx \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{T}\frac{CF_i(j)}{(1+r_{i,j})^j} \tag{1.3}$$

Où N est le nombre de simulations, T l'horizon de projection, $CF_i(j)$ le flux de trésorerie net de l'année j pour la simulation i, et $r_{i,j}$ le taux d'actualisation sans risque pertinent.

3. La valeur comptable (ou coût historique) correspond au prix d'acquisition de l'actif, tandis que la valeur de marché représente le prix auquel l'actif pourrait être échangé dans les conditions de marché actuelles.
4. Ces deux composantes sont définis de manière détaillée dans les paragraphes suivants.

La **marge de risque** (*Risk Margin* - RM) complète le Best Estimate. Elle correspond à la rémunération du capital réglementaire qui doit être immobilisé pour couvrir les risques non-financiers (longévité, rachat, etc.) jusqu'à l'extinction du portefeuille. Son calcul repose sur une approche dite de coût du capital (*Cost of Capital* - CoC), qui consiste à actualiser le coût futur de détention de ce capital :

$$RM = \mathrm{CoC}_{\mathrm{rate}} \times \sum_{j=0}^{T} \frac{\mathrm{SCR}_{\text{non-fi}}(j)}{(1+r_{j+1})^{j+1}} \tag{1.4}$$

Où $\mathrm{CoC}_{\mathrm{rate}}$ est le coût du capital (fixé à 6%), et $\mathrm{SCR}_{\text{non-fi}}(j)$ est la part du SCR couvrant les risques non-financiers à l'année j.

1.2.1.3 Les fonds propres et les exigences de capital

Les fonds propres prudentiels, aussi appelés **NAV (*Net Asset Value*)**, constituent la richesse de l'assureur. Ils sont définis par la différence entre la valeur des actifs et celle des engagements :

$$NAV = VM_{Actifs} - (BE + RM) \tag{1.5}$$

Ce sont ces fonds propres qui doivent permettre à l'assureur d'absorber des pertes inattendues.

Le Solvency Capital Requirement **(SCR)** est le montant de fonds propres nécessaire pour absorber des pertes exceptionnelles. Il est calibré pour correspondre à la Value-at-Risk **(VaR)** à 99,5 % de la NAV sur un horizon d'un an.

Le calcul du SCR s'effectue le plus souvent via la formule standard définie par la réglementation. Cette dernière est une approche qui décompose le risque total en plusieurs modules (marché, souscription vie, etc.), eux-mêmes divisés en sous-modules. Pour chaque risque élémentaire x, le capital requis est calculé comme la perte de NAV consécutive à un choc instantané :

$$SCR_x^{\mathrm{net}} = \Delta NAV = NAV_{\mathrm{central}} - NAV_{\mathrm{choc}\ x} \tag{1.6}$$

Cette exigence en capital est dite "nette" car elle prend en compte la capacité d'absorption des pertes des provisions techniques (Adj_{FDB}), matérialisant l'effet amortisseur de la participation aux bénéfices en cas de choc défavorable.

Dans le cadre des projections ALM menées au sein de ce mémoire, l'analyse se concentrera sur l'évaluation précise de ces exigences nettes (SCR_x^{net}) pour les modules les plus impactés par notre étude. Ainsi, une attention particulière sera portée aux risques techniques (biométriques et comportementaux) et financiers, à travers l'application des chocs réglementaires suivants au portefeuille :

- **Le risque de mortalité et de longévité :** Modélisé par une altération structurelle des probabilités de décès.
- **Le risque de rachat (hausse, baisse et massif) :** Évalué à travers une dérive pérenne des lois de rachats et un choc de sortie brutale la première année de projection.

— **Le risque de taux d'intérêt (hausse et baisse) :** Caractérisé par une déformation de la courbe des taux sans risque.

— **Le risque actions et immobilier :** Matérialisé par une baisse instantanée de la valeur de marché de ces actifs.

Bien que l'analyse menée dans ces travaux se concentre sur les sensibilités modulaires, il convient de rappeler que, dans le processus réglementaire complet, l'ensemble de ces risques est ensuite agrégé au moyen d'une matrice de corrélation pour former le SCR global (*Basic Solvency Capital Requirement* - BSCR), tel qu'illustré par le schéma de la Formule Standard ci-dessous :

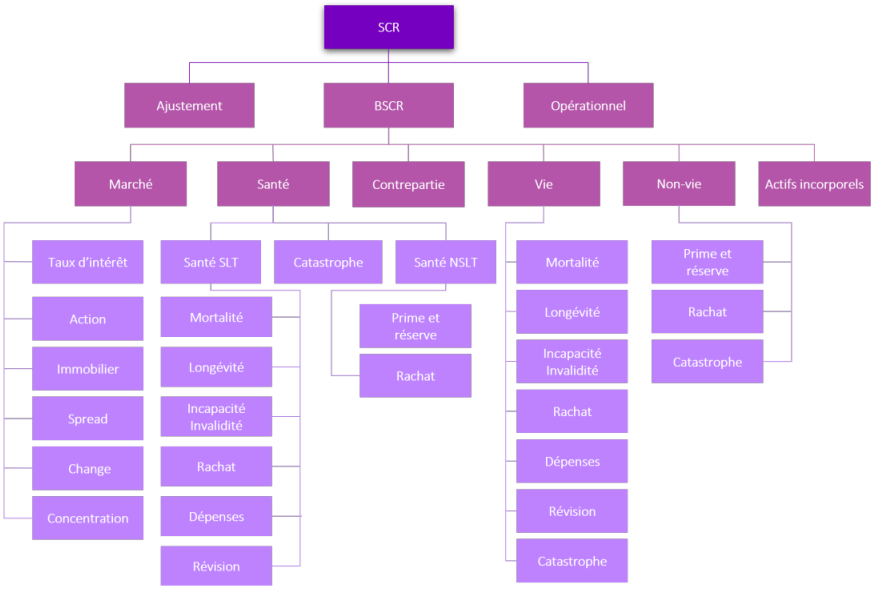

FIGURE 1.4 – Schéma des modules et sous-modules du SCR en Formule Standard

L'évaluation de la déformation du bilan face à l'ensemble de ces chocs requiert une projection de long terme sur un grand nombre de scénarios stochastiques. La réalisation de cet exercice repose sur trois parties fondamentales qui seront détaillées dans les sections suivantes : les GSE pour simuler l'environnement financier, les techniques avancées d'agrégation du passif (*Model Points*) pour réduire le temps des calculs, et enfin l'architecture du modèle de projection ALM qui orchestre les interactions Actif-Passif.

1.3 Les Générateurs de Scénarios Économiques (GSE)

Le Générateur de Scénarios Économiques est un outil mathématique central dans la modélisation stochastique. Il a pour fonction de simuler de multiples trajectoires futures pour les principales variables financières (taux d'intérêt, performance des actions, inflation, etc.). La qualité des projections ALM dépendant directement de la robustesse du GSE, la sélection et le paramétrage des modèles mathématiques sous-jacents sont des enjeux déterminants.

1.3.1 Le choix de l'univers de projection

La modélisation stochastique s'appuie historiquement sur deux cadres distincts, dont les finalités diffèrent complètement : l'univers « monde réel » ($\mathbb{P}$) et l'univers « risque neutre » ($\mathbb{Q}$).

Le monde réel ($\mathbb{P}$) intègre des primes de risque afin de refléter une évolution économique plausible, le rendant indispensable pour le pilotage stratégique prospectif et les exercices du Pilier 2. Toutefois, les travaux menés au sein de ce mémoire se concentrant exclusivement sur l'évaluation des provisions techniques (*Best Estimate*) et des exigences de capital (SCR) relevant du Pilier 1, seul l'univers risque neutre ($\mathbb{Q}$) sera exploité.

L'**univers Risque Neutre ($\mathbb{Q}$)** est un cadre de valorisation théorique requis pour les calculs *market-consistent*. Son objectif n'est pas de prédire l'évolution réelle des marchés, mais de calculer une valeur juste en se fondant sur les prix observés. Dans cet univers, on suppose que tous les investisseurs sont indifférents au risque, ce qui implique que le rendement espéré de n'importe quel actif est strictement égal au taux d'intérêt sans risque. Cette construction, fondée sur l'absence d'opportunité d'arbitrage, est indispensable pour valoriser de manière cohérente le coût des garanties financières complexes. La valeur V_0 d'un flux de trésorerie futur CF_T est alors son espérance mathématique sous cette probabilité risque neutre, actualisée au taux sans risque $r(s)$:

$$V_0 = \mathbb{E}^{\mathbb{Q}}\left[CF_T \cdot e^{-\int_0^T r(s)ds}\right] \tag{1.7}$$

1.3.2 Les modèles de diffusion en univers risque neutre

Afin de générer ces trajectoires économiques, le GSE s'appuie sur des équations différentielles stochastiques spécifiques au comportement de chaque classe d'actifs.

1.3.2.1 Modélisation des taux d'intérêt : le modèle de Hull & White

Pour les taux d'intérêt, le modèle de **Hull & White à un facteur** est une référence dans le cadre réglementaire. Son principal avantage est sa capacité à se calibrer parfaitement à la courbe des taux sans risque initiale, telle que fournie par l'EIOPA.

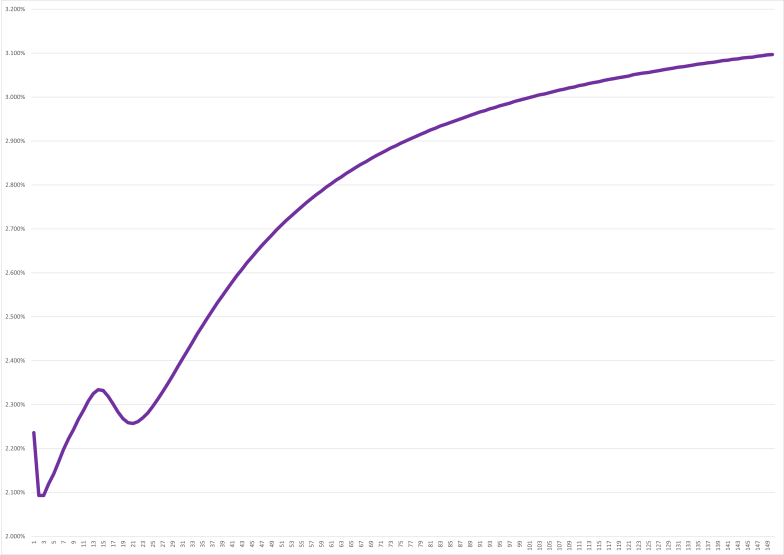

FIGURE 1.5 – Courbe des taux sans risque sans *Volatility Adjustment* au 31/12/2024 publiée par l'EIOPA
Se limiter à 40 ans, on voit pas bien l'abscisse

Cette flexibilité est obtenue grâce à un paramètre de retour à la moyenne $\theta(t)$ qui dépend du temps. Son équation différentielle stochastique (EDS) s'écrit :

$$dr_t = (\theta(t) - ar_t)dt + \sigma dW_t^{\mathbb{Q}} \tag{1.8}$$

où r_t est le taux d'intérêt court, a la vitesse de retour à la moyenne, σ la volatilité et $W_t^{\mathbb{Q}}$ un mouvement brownien sous la mesure risque neutre. Pour des raisons de calcul, nous utilisons la solution discrète de cette EDS :

$$r_{t+h} = r_t e^{-ah} + \theta(t+h) - \theta(t)e^{-ah} + \sigma\sqrt{\frac{1-e^{-2ah}}{2a}}Z \tag{1.9}$$

1.3.2.2 Modélisation des actions et de l'immobilier : le modèle de Black & Scholes

Pour les actifs risqués comme les actions ou l'immobilier, le modèle de **Black & Scholes** est couramment utilisé. Conformément à la logique risque neutre, le rendement espéré est le taux sans risque r_t. L'EDS du prix de l'actif S_t est :

$$dS_t = r_t S_t dt + \sigma S_t dW_t^{\mathbb{Q}} \tag{1.10}$$

où S_t est le prix de l'actif, r_t le taux sans risque et σ la volatilité de l'actif. La solution de cette EDS est donnée par :

$$S_t = S_0 \exp\left(\int_0^t \left(r_s - \frac{\sigma^2}{2}\right) ds + \int_0^t \sigma dW_s^{\mathbb{Q}}\right) \tag{1.11}$$

En pratique, on utilise sa solution discrétisée pour simuler les trajectoires de prix sur un pas de temps h :

$$S_{t+h} = S_t \exp\left(\left(r_t - \frac{\sigma^2}{2}\right) h + \sigma\sqrt{h}Z\right) \tag{1.12}$$

où Z est une variable aléatoire suivant une loi normale centrée réduite $\mathcal{N}(0,1)$.

Une fois cet environnement financier stochastique modélisé, la seconde brique fondamentale de l'évaluation des sensibilités réside dans la projection du passif. Face à la volumétrie massive des contrats d'assurance vie, une modélisation exhaustive contrat par contrat s'avère opérationnellement inenvisageable sur un grand nombre de scénarios. Il est dès lors impératif de recourir à des techniques de réduction de la taille du portefeuille, concept qui introduit la nécessité de regrouper les contrats sous forme de *Model Points*.

1.4 La représentation du passif : le concept de *Model Point*

1.4.1 Enjeux de l'agrégation et réduction de la dimension

Les portefeuilles d'assurance vie comptent souvent des centaines de milliers, voire des millions de polices. Une modélisation "ligne à ligne" est techniquement possible mais informatiquement très chronophage pour des calculs stochastiques complexes comme ceux requis par les modèles ALM, où chaque contrat doit être projeté sur des milliers de scénarios économiques.

La charge de calcul deviendrait excessive. La simplification du portefeuille de passif n'est donc pas un choix, mais une contrainte opérationnelle majeure. La réponse standard à cette contrainte est la création de ***Model Points*** (MP). Un MP est un contrat synthétique représentant un agrégat de polices partageant des caractéristiques homogènes (âge, ancienneté, type de produit, TMG). L'objectif est de réduire drastiquement le volume de données à traiter tout en préservant les propriétés actuarielles et financières essentielles du portefeuille complet.

1.4.2 Cadre réglementaire et exigences de validation

Si l'agrégation est une nécessité opérationnelle, elle constitue également un risque de modèle. Le remplacement d'un portefeuille réel par une image simplifiée introduit inévitablement un biais d'estimation. Dans le cadre prudentiel de Solvabilité II, ces simplifications sont encadrées strictement.

1.4.2.1 Le principe de matérialité et justification des approximations

La directive Solvabilité II et les textes de l'ACPR imposent que les méthodes de simplification soient appropriées et ne conduisent pas à une sous-estimation significative des risques. En particulier, la *Notice ACPR sur les modèles internes* (2023) [2] rappelle dans son paragraphe 21 que l'entreprise doit « identifier, documenter et justifier la pertinence des simplifications, des approximations et des hypothèses »utilisées. Bien que ce texte vise les modèles internes, il établit un standard de place : l'erreur introduite par l'agrégation doit rester immatérielle au regard du BEL et du SCR.

Les autorités de contrôle (ACPR, EIOPA) insistent sur deux points majeurs :

— **La granularité adaptée (Segmentation) :** Comme précisé dans le paragraphe 38 de la notice, la granularité des facteurs de risque et la segmentation doivent être justifiées en analysant les avantages et les inconvénients. Une segmentation trop grossière (ex : moyenne des âges sur tout le portefeuille) écraserait la convexité des engagements et sous-estimerait la valeur des options et garanties.

— **La validation quantitative :** L'entreprise doit démontrer, chiffres à l'appui, que le passage du *réel* au *modèle* n'altère pas significativement les indicateurs clés (BEL, SCR).

1.4.3 Dispositif de contrôle de la qualité de l'agrégation

Pour répondre à ces exigences, la construction des *Model Points* doit s'accompagner d'un dispositif de validation robuste, intégré à la gouvernance des risques. Ce dispositif repose généralement sur trois niveaux de contrôle.

1.4.3.1 Tests de reproduction des métriques statiques

Il s'agit de vérifier, à la date d'arrêté, que le portefeuille agrégé reproduit fidèlement les stocks du portefeuille réel. Les écarts relatifs sont mesurés sur des indicateurs clés tels que :

— La PM totale et par segment ;

— Les encours moyens, l'âge moyen pondéré des assurés, l'ancienneté moyenne ;

— La répartition par TMG.

Des seuils de tolérance stricts (par exemple $< 0.1\%$ d'écart sur la PM) sont définis par l'assureur pour valider cette étape.

1.4.3.2 Contrôles du profil de risque et des queues de distribution

L'agrégation ne doit pas lisser les risques extrêmes. Un point d'attention particulier, souligné par les contrôles prudentiels (paragraphe 39 de la notice ACPR), est la bonne représentation des queues de distribution. Par exemple, un portefeuille contenant quelques très gros contrats ou des contrats très anciens avec des TMG très élevés (4.5%) ne doit pas voir ces risques dilués dans une moyenne à 0% comme c'est le cas pour les contrats récents. Ces profils atypiques nécessitent souvent la création de *Model Points* dédiés pour isoler le risque.

1.4.3.3 Tests de sensibilité et stabilité dynamique

La validation la plus importante concerne le comportement du portefeuille agrégé face aux chocs. En effet, un regroupement peut être correct en vision statique ($t = 0$) mais s'éloigner de la réalité lors des projections. Il est donc nécessaire de tester la robustesse des *Model Points* de manière dynamique via des tests de sensibilité. Cela consiste à comparer les résultats d'une projection détaillée police à police avec ceux du modèle agrégé, en appliquant les chocs réglementaires (taux, rachats, mortalité) définis précédemment.

L'objectif est de vérifier que l'agrégation préserve bien la convexité du passif et sa sensibilité aux variations économiques, afin de garantir un calcul juste du SCR. C'est pour répondre à ce besoin que ce mémoire compare plusieurs méthodes de regroupement.

1.5 Gestion actif-passif et architecture du modèle de projection

La gestion actif-passif est la réponse opérationnelle à l'inadéquation structurelle inhérente au cycle de production inversé de l'assurance vie. Cette discipline vise à piloter les risques nés de l'interdépendance entre :

— **Le passif :** Des engagements souvent de long terme, dont l'évaluation est particulièrement sensible à l'environnement économique (notamment via les garanties de taux lorsqu'elles existent) et aux comportements des assurés (options de rachat).

— **L'actif :** Un portefeuille d'investissements dont le rendement permet d'honorer les garanties et de revaloriser l'épargne.

Pour quantifier ces risques et répondre aux exigences de Solvabilité II, il est nécessaire de projeter sur un long horizon de projection le bilan de l'assureur sur un grand nombre de scénarios économiques. Cette section détaille les mécanismes de cette projection et l'architecture du modèle développé en Python pour ce mémoire.

1.5.1 Mécanismes de projection et interactions actif-passif

La projection repose sur la modélisation des flux financiers et des règles de gestion qui lient l'actif et le passif.

L'approche stochastique vs déterministe

Si une approche déterministe, reposant sur un unique scénario central, s'avère suffisante pour l'élaboration d'un *Business Plan*, elle demeure incapable de capturer la valeur temps des options et garanties financières (telles que les TMG ou les options de rachat). Le recours à une modélisation stochastique est par conséquent indispensable. Cette méthode consiste à simuler plusieurs milliers de trajectoires économiques (générées via le GSE présenté en section 1.3). L'agrégation de ces simulations permet, d'une part, d'évaluer la moyenne des résultats par la méthode de Monte-Carlo (nécessaire au calcul du *Best Estimate*) et, d'autre part, d'obtenir une distribution empirique complète des résultats. C'est l'analyse des quantiles de cette distribution qui rend possible l'estimation de la *Value-at-Risk*[5] (VaR) et finalement de déterminer le SCR.

5. La *VAR* est une mesure de risque indiquant la perte potentielle maximale d'un portefeuille sur un horizon temporel donné, pour un niveau de confiance fixé. Dans le référentiel Solvabilité II, le SCR est défini comme la VaR de la variation de l'actif net à l'horizon d'un an, avec un seuil de confiance de 99,5 %.

1.5.2 Algorithmes de projection du passif et valorisation du Best Estimate

Contrairement aux modèles traditionnels procédant par itération sur chaque contrat (boucle ligne à ligne), ce modèle exploite la vectorisation pour projeter simultanément l'ensemble des *Model Points* sur tous les scénarios.

Cette approche permet de traiter des volumes de données massifs en définissant l'espace de projection comme le produit cartésien :

$$\Omega = \{MP\} \times \{\text{Années}\} \times \{\text{Scénarios}\} \times \{\text{Chocs}_{\text{S2}}\}$$

Les paragraphes suivants détaillent la mécanique actuarielle de projection sur un pas de temps annuel $[t, t+1[$.

Algorithme de projection des flux de passif

Ici il faut faire attention : les presta sont appliquées à mi période et calculées à mi période ou à fin de période ? La projection des engagements s'effectue selon une logique de flux en fin de période, adaptée pour simuler la survenance continue des événements. Pour chaque année projetée t, l'évolution de laPM suit la séquence d'opérations suivante :

1. **Vieillissement et mise à jour des statuts :** L'âge et des assurés et l'ancienneté des contrats sont incrémentées, passant de x à $x+1$. Les contrats arrivant à terme sont sortis du stock et le capital constitué est versé.
2. **Calcul des taux de sortie (Décréments) :** Le modèle applique les tables biométriques et comportementales pour déterminer les probabilités de sortie :
   - **Mortalité (q_{x+t}) :** Application des tables réglementaires ou d'expérience (par génération ou par âge atteint).
   - **Rachats (α_t) :** Application du taux de rachat total lié à l'ancienneté du contrat.
3. **Valorisation intermédiaire et calcul des prestations :** Afin de simuler une distribution uniforme des décès et des rachats au cours de l'année, le modèle calcule une PM revalorisée à mi-période $(t+0.5)$ sur laquelle sont appliqués les taux de sortie.

   $$PM_{t+0.5} = PM_t \times (1+TMG)^{0.5}$$

   Les flux de prestations ($P_{MP,t}$) versées sur un *Model Point* l'année t sont alors déduits :

   $$P_{MP,t} = \underbrace{PM_{MP,t+0.5} \times q_{MP,x+t}}_{\text{Prestations Décès}} + \underbrace{PM_{MP,t+0.5} \times (1-q_{MP,x+t}) \times \alpha_{MP,t}}_{\text{Prestations Rachat}} \tag{1.13}$$

   Cette approche assure la cohérence entre la valeur de l'épargne acquise au moment du départ et les montants effectivement versés.
4. **Prélèvement des frais et capitalisation du stock restant :** Les chargements ($Ch_{MP,t}$) et frais

de gestion ($Fg_{MP,t}$) sont prélevés sur l'encours. remarque d'Aurélien : frais sont pris à part sur les montants de chargement et non sur l'encours direct => marge de gestion ? ? Le stock restant continue de capitaliser au TMG sur la seconde moitié de l'année. La PM d'un *Model Point* avant participation aux bénéfices s'écrit alors :

$$PM_{MP,t+1}^{\text{avant PB}} = PM_{MP,t} \times (1+TMG_{MP}) - P_{MP,t} \times (1+TMG_{MP})^{0.5} - (Ch_{MP,t} + Fg_{MP,t}) \quad (1.14)$$

5. **Revalorisation finale et participation aux bénéfices :** En fin d'année, l'interaction centrale de l'ALM s'opère via la distribution de la performance financière. Le module détermine le taux de revalorisation global ($Tx_{\text{servi},t}$) en simulant la stratégie discrétionnaire de l'assureur selon le mécanisme suivant :

   — Calcul du résultat financier (produits financiers nets de charges) ;

   — Détermination de l'assiette de PB réglementaire ;

   — Application de la politique commerciale (recherche d'un taux cible concurrentiel) ;

   — Dotation ou reprise à la PPE pour lisser les rendements dans le temps. rq lucas : schéma serait pas mal surtout si tu as des mécanismes pour servir le tx cible

   Une fois ce taux global défini, la participation aux bénéfices additionnelle ($PB_{MP,t}$) est allouée à chaque *Model Point*. Elle n'est versée que si le taux servi excède le taux déjà garanti contractuellement :

$$PB_{MP,t} = \overline{PM}_{MP,t} \times \max\left(0, Tx_{\text{servi},t} - TMG_{MP}\right) \quad (1.15)$$

   Où $\overline{PM}_{MP,t}$ désigne la provision mathématique moyenne du *Model Point* sur l'année de projection t.

   La PM finale du *Model Point* pour l'année $t+1$ est donc :

$$PM_{MP,t+1} = PM_{MP,t}^{\text{avant PB}} + PB_{MP,t} \quad (1.16)$$

Méthodologie de calcul du Best Estimate

Conformément aux exigences de Solvabilité II, le *BE* correspond à la moyenne des valeurs actuelles des flux de trésorerie futurs, pondérée par leur probabilité de réalisation.

Définition des flux nets de trésorerie (CF_t) Pour chaque pas de temps t et chaque scénario, le modèle agrège les flux entrants et sortants du point de vue de l'assureur :

$$CF_t = \text{Prestations}_t + \text{Frais de Gestion}_t - \text{Primes}_t \quad (1.17)$$

commissions prises en compte dans le modèle ? Si oui ajouter à la formule ci-dessus

À noter que les chargements prélevés sur l'épargne ne constituent pas des flux de trésorerie (ils restent au sein de l'entreprise), mais viennent diminuer la dette envers les assurés.

Actualisation et agrégation L'actualisation repose sur l'utilisation de **déflateurs stochastiques** $D(0,t)$, fournis par le GSE en cohérence avec la courbe des taux sans risque. Le déflateur intègre intrinsèquement le facteur d'actualisation et la mesure de probabilité risque-neutre $\mathbb{Q}$.

Le Best Estimate est obtenu par la moyenne arithmétique (méthode de Monte-Carlo) sur l'ensemble des N scénarios simulés :

$$BE = \frac{1}{N}\sum_{s=1}^{N}\left(\sum_{t=1}^{T} CF_{s,t} \times D_s(0,t)\right) \tag{1.18}$$

si flux pas tous en fun de période, revoir la formule

Cette approche par déflateurs permet de valoriser de manière cohérente les options et garanties financières (l'effet cliquet des TMG) qui ne seraient pas capturées par une simple actualisation déterministe.

1.5.3 Limites actuelles du modèle

À date, bien que le modèle projette finement les provisions techniques et les actifs, la dynamique des fonds propres n'est pas entièrement modélisée. Cette limitation empêche le calcul direct d'un ratio de solvabilité projeté, mais n'impacte pas la qualité des sensibilités sur le BE et le SCR, qui constituent le cœur de ce mémoire.

Les limites actuelles du modèle résident dans l'absence de modélisation des rachats conjoncturels, une restriction qui impacte fortement la mesure du risque de rachat dans le référentiel S2. Intégrer la sensibilité des comportements clients aux évolutions du marché constitue une piste d'amélioration significative. Dans la même logique, la règle d'attribution de la PB pourrait être enrichie afin de traduire des stratégies de distribution plus complexes et réalistes.

Ces évolutions font partie des perspectives d'amélioration du modèle, mais ne remettent pas en cause sa capacité à produire des indicateurs fiables pour les analyses de sensibilité qui sont au cœur de ce mémoire.

Chapitre 2

Construction d'un générateur de portefeuilles de passifs

2.1 Objectifs stratégiques et contraintes techniques

La pertinence de l'analyse de sensibilité repose sur la qualité du portefeuille de passif initial. En l'absence de données réelles accessibles, pour des raisons évidentes de confidentialité liées à l'environnement du conseil, l'un des enjeux majeurs de ce mémoire consiste en l'élaboration d'un générateur de passifs réalistes. Cet outil a pour objectif de simuler un ensemble de contrats dont les caractéristiques biométriques et financières permettent une modélisation fidèle des engagements, constituant ainsi le socle de l'étude comparative sur l'agrégation.

Ce chapitre détaille la conception d'un outil de génération de passifs destiné à produire un portefeuille de contrats d'assurance vie représentatif du marché. Les enjeux analytiques justifiant le recours à une telle simulation pour l'étude de Solvabilité 2 sont d'abord présentés. La méthodologie de génération et les contraintes de calibration font ensuite l'objet d'une analyse spécifique. Enfin, les données utilisées sont explicitées pour démontrer la cohérence statistique et le réalisme du portefeuille obtenu.

2.1.1 Définition du générateur de portefeuilles de passifs

Le générateur de portefeuille de passifs développé dans le cadre de ce mémoire est un outil conçu pour créer des ensembles de données synthétiques qui imitent avec réalisme des portefeuilles de contrats d'assurance-vie. Plutôt que de s'appuyer sur des données réelles, souvent confidentielles ou indisponibles, cet outil simule les caractéristiques fondamentales des assurés (âge, sexe, etc.) et de leurs contrats (type de produit, montant de la PM, date de souscription, etc.).

L'objectif n'est pas de produire des données aléatoires, mais de générer un portefeuille dont les propriétés statistiques, distributions, corrélations, tendances, sont indiscernables de celles d'un portefeuille réel. Pour cela, toutes les lois et hypothèses ont été calibrées sur des données publiques de marché. Avoir des données fiables est très important pour produire des résultats de qualité dans le cadre d'analyses ou de décisions stratégiques, c'est pourquoi le développement d'un tel outil s'est imposé comme une nécessité.

2.1.2 Besoins métiers : simulation de nouveaux produits et analyse concurrentielle

Pour un acteur du secteur de l'assurance, la capacité à modéliser et à anticiper les dynamiques de marché est un avantage concurrentiel décisif. Le générateur de portefeuilles de passifs répond directement à ce besoin en fournissant un support quantitatif pour la prise de décision stratégique. Il permet par exemple à un cabinet de conseil de tester ses modèles sans dépendre des données clients, et à un assureur d'explorer des scénarios prospectifs ou d'évaluer l'impact de nouvelles offres. Son utilité se manifeste dans trois domaines clés pour les assureurs : le lancement de nouveaux produits, l'orientation du *business mix* et l'analyse concurrentielle.

Premièrement, le lancement d'un nouveau produit d'assurance-vie représente un investissement et un risque significatifs. Avant toute commercialisation, il est impératif d'en évaluer rigoureusement les impacts sur le profil de risque et la rentabilité de l'entreprise. Le générateur offre un véritable laboratoire virtuel

pour effectuer ces tests. En simulant l'intégration de milliers de polices conformes aux caractéristiques du nouveau produit (garanties, frais, options), il permet de projeter leur comportement dans le temps. Il devient alors possible d'analyser leur effet sur les indicateurs prudentiels de Solvabilité II, tels que le BE et le SCR, mais aussi d'évaluer leur sensibilité à divers chocs de marché (hausse des taux, krach boursier) ou de comportement (vagues de rachats). Cet outil permet ainsi de tester, d'ajuster et d'optimiser les caractéristiques d'un produit pour atteindre le couple rendement/risque désiré avant même sa mise sur le marché.

Deuxièmement, le générateur est un outil précieux pour piloter la stratégie à long terme de l'entreprise. La direction peut être amenée à vouloir faire évoluer son *business mix*, c'est-à-dire la répartition de son portefeuille entre différents types de produits (fonds en euros, unités de compte, prévoyance...). Par exemple, dans un contexte de taux bas persistants, un assureur pourrait vouloir accélérer sa transition vers les produits en unités de compte. Le générateur permet génerer des portefeuilles qui constituent une base pour le modèle ALM qui pourra quantifier les implications d'une telle stratégie. En simulant des portefeuilles futurs correspondant à ces nouvelles orientations commerciales, la direction peut visualiser les conséquences sur le bilan, la rentabilité prévisionnelle, mais aussi sur la consommation de capital et l'exposition aux risques. Ces simulations éclairent les décisions stratégiques et s'intègrent naturellement dans des exercices prospectifs comme l'ORSA (*Own Risk and Solvency Assessment*).

Enfin, la capacité à se positionner par rapport à ses concurrents est fondamentale. Faute d'accès aux portefeuilles détaillés des autres acteurs, un assureur doit s'appuyer sur des reconstitutions. En se basant sur des données publiques (rapports annuels ou publications réglementaires comme les Rapport sur la Solvabilité et la Situation Financière) ou des statistiques sectorielles, le générateur peut permettre la création d'un portefeuille représentatif du marché, ou simuler le portefeuille probable d'un concurrent spécifique. Ces portefeuilles synthétiques deviennent alors une base solide pour des analyses comparatives (*benchmarking*). Ils permettent non seulement d'évaluer la performance relative, mais aussi de comparer les profils de risque, d'anticiper les stratégies concurrentes et d'identifier les meilleures pratiques du marché. Il convient toutefois de souligner les limites d'une telle démarche. Une analyse ALM complète et réaliste d'un concurrent ne peut se contenter de la seule modélisation du passif. Elle exigerait également de simuler son portefeuille d'actifs et de disposer d'informations précises sur ses ressources financières et ses fonds propres. Or, ces données sont rarement publiques. Par conséquent, l'analyse comparative reste nécessairement partielle, se concentrant sur les caractéristiques intrinsèques du portefeuille de passifs reconstitué.

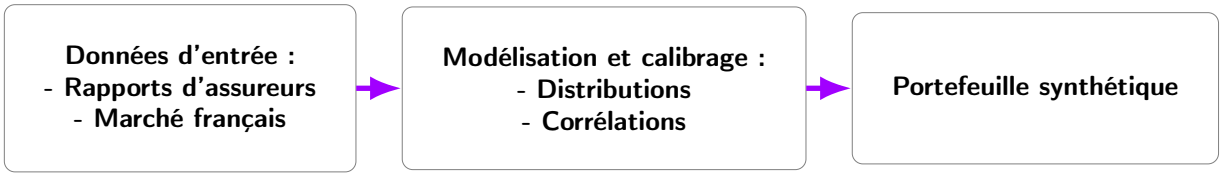

FIGURE 2.1 – Schéma de la méthodologie de génération d'un portefeuille de passifs synthétique. Moche à refaire

2.1.3 Défis de la modélisation : réalisme, volumétrie et flexibilité

La conception et la mise en œuvre d'un générateur de portefeuilles de passifs efficace soulèvent deux défis majeurs :

— **Le réalisme des données générées :** Il s'agit du défi le plus complexe. L'objectif n'est pas de produire des données aléatoires, mais de créer un portefeuille synthétique dont les propriétés statistiques sont indiscernables de celles d'un portefeuille réel. Cela implique non seulement de reproduire fidèlement les distributions de chaque caractéristique individuelle (âge, montant, etc.), mais aussi, et surtout, de capturer les corrélations complexes qui les lient. Par exemple, l'âge d'un assuré est souvent corrélé au type de produit souscrit et au montant de sa provision mathématique. Ignorer ces dépendances conduirait à un portefeuille incohérent, dont le comportement sous différents scénarios de risque serait erroné, invalidant ainsi les analyses prudentielles ou stratégiques qui en découlent.

— **La gestion de la volumétrie :** Les portefeuilles d'assurance-vie des grands acteurs du marché se comptent en centaines de milliers, voire en millions de contrats. Le générateur doit être capable de produire des ensembles de données de cette ampleur de manière performante, c'est-à-dire dans un temps de calcul raisonnable et sans consommer une quantité excessive de ressources mémoire. Cette contrainte de performance est d'autant plus forte que la gestion des corrélations, nécessaire au réalisme du portefeuille, ajoute une complexité de calcul significative. Il faut donc trouver un équilibre entre la complexité statistique et la performance, ce qui a des implications directes sur les choix techniques et algorithmiques.

La section suivante présente en détail la méthodologie de modélisation probabiliste qui a été développée pour construire un portefeuille à la fois réaliste et volumineux.

2.2 Méthodologie de génération et modélisation statistique

La méthodologie de génération du portefeuille de passifs synthétique repose sur une approche probabiliste. L'objectif est de construire un ensemble de contrats d'assurance dont les propriétés statistiques sont entièrement maîtrisées. Pour ce faire, chaque caractéristique d'un contrat (âge de l'assuré, montant de la provision, etc.) est modélisée comme une variable aléatoire, tirée d'une loi de probabilité préalablement calibrée sur des données de marché quand elles sont disponibles. Sinon, des hypothèses ont été formulées pour recréer ces variables de la manière la plus réaliste possible.

2.2.1 Approche stochastique par lois de probabilité

La génération du portefeuille synthétique s'appuie sur une modélisation stochastique où chaque attribut d'un contrat est représenté par une variable aléatoire. Dans un premier temps, l'objectif est de générer un portefeuille complet, représentatif du marché. Pour ce faire, une loi de probabilité marginale est définie pour chaque caractéristique, avec des paramètres rigoureusement calibrés sur des données de marché. Certaines variables sont ensuite liées entre elles pour refléter les dépendances observées dans les portefeuilles réels. Ce même cadre peut ensuite être adapté pour simuler un produit spécifique ; il suffirait alors de générer des variables aléatoires de manière conditionnelle aux caractéristiques de ce produit. Cette méthode garantit à la fois le réalisme statistique du portefeuille et la flexibilité nécessaire aux analyses prospectives.

Les sections suivantes détailleront la méthodologie de calibration pour les variables fondamentales qui structurent le portefeuille :

— L'âge de l'assuré ;

— L'âge à la souscription, qui détermine l'ancienneté du contrat ;

— Le montant de la PM.

D'autres variables, telles que le sexe ou la répartition des supports, seront également modélisées pour compléter le profil de chaque contrat.

2.2.1.1 Modélisation de l'âge des assurés

La première étape a consisté à construire une distribution de probabilité réaliste à partir de deux sources de données :

1. **La pyramide des âges de la population française** pour l'année 2024 [7], fournissant la structure démographique de base entre 0 et 100 ans.
2. **Une étude statistique de l'INSEE** sur la détention d'assurance-vie par tranche d'âge en France [6]

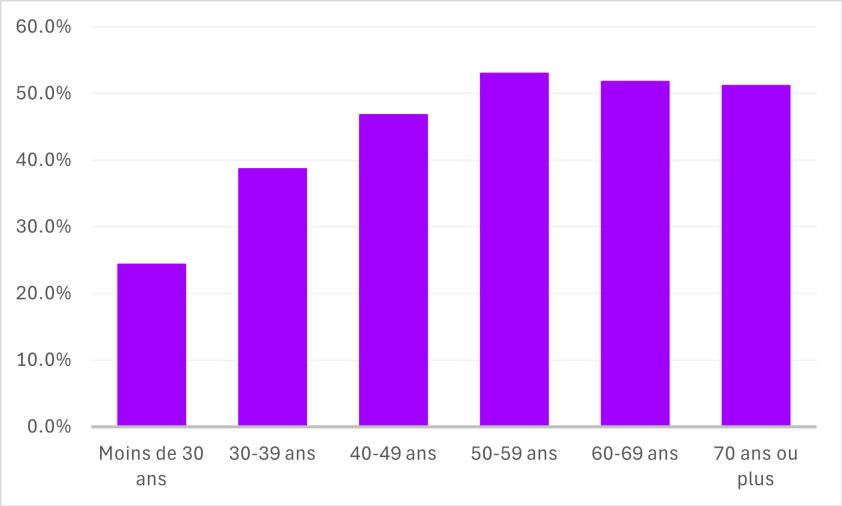

FIGURE 2.2 – Proportion de détention d'assurance-vie par tranche d'âge en France [6].

Afin de transformer les données discrètes de l'INSEE, présentées par tranches d'âge, en une distribution continue du taux de détention par âge, une méthodologie d'interpolation a été mise en œuvre. Cette étape est cruciale pour pouvoir ensuite simuler l'âge des assurés de manière réaliste.

L'approche a consisté à définir d'abord des points de données représentatifs pour chaque tranche d'âge fournie. Les choix suivants ont été faits :

— Pour la tranche des moins de 30 ans, plusieurs points ont été positionnés entre 18 et 30 ans afin de modéliser la croissance progressive de la détention en début de vie active.

— Pour les tranches intermédiaires (par exemple, 30-39 ans), le point central de l'intervalle a été retenu.

— Pour la tranche des 70 ans et plus, un âge représentatif de 80 ans a été choisi car à partir de cet âge la souscription/résiliation du contrat d'assurance est rare.

Une fois ces points définis, une interpolation PCHIP (*Piecewise Cubic Hermite Interpolating Polynomial* : interpolation par morceaux concervant la monotonie et utilisant des polynômes de degré trois) a été appliquée sur la partie de la courbe de 0 à 80 ans. Cette méthode a été privilégiée car elle évite les oscillations artificielles qu'une interpolation cubique aurait généré et garantit que la proportion de détention reste croissante comme ce que suggérent les données . Pour les âges plus avancés, une interpolation linéaire a été utilisée pour assurer une transition douce, suivie d'un plateau constant après 80 ans. Cette dernière hypothèse modélise une stabilisation du comportement de détention chez les assurés les plus âgés avec une absence de rachats.

Le résultat de ce processus est une fonction continue et lisse qui estime le taux de détention d'assurance-vie pour chaque âge entre 18 et 100 ans, comme illustré par la figure 2.3.

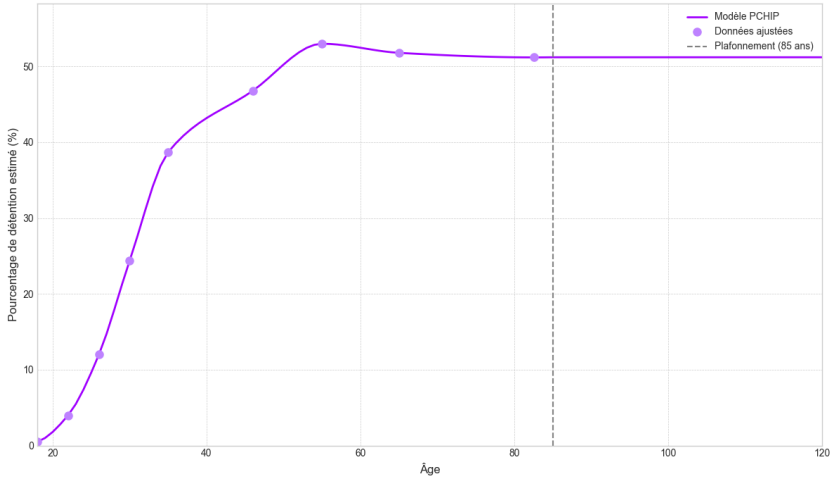

FIGURE 2.3 – Proportion de détention d'assurance-vie par âge en France par diverses méthodes d'interpolation. TODO : modifier légende et titre pour plus de lisibilité + refaire la modélisation avec 80 ans et non 82.5 ans

En multipliant la population de chaque âge par le taux de détention estimé, il a été possible d'obtenir une estimation du nombre d'assurés pour chaque âge et chaque sexe. Après standartisation, on peut alors construire une loi de probabilité empirique. :

$$P(Age = x) = \frac{N_{assures}(x)}{Total_{assures}} \tag{2.1}$$

Calibration d'une loi usuelle sur la loi empirique

Deux lois de probabilité continues ont été sélectionnées comme candidates pour modéliser la distribution empirique : la **loi Gamma** et la **loi Beta**. Les paramètres de ces deux lois ont été estimés par la méthode du maximum de vraisemblance sur un échantillon de 200 000 individus tirés de la loi empirique. Pour déterminer la loi la plus adéquate, des critères visuels et statistiques (Test de Kolmogorov-Smirnov [1], AIC [2], BIC [3] [4]) ont été utilisés. La figure 2.4 montre l'ajustement de la loi Beta qui a des meilleurs résultats statistiques et qui épouse mieux la distribution empirique que la loi Gamma (figure 5.2).

1. Le test de Kolmogorov-Smirnov est un test d'adéquation non paramétrique comparant la fonction de répartition empirique d'un échantillon à celle d'une loi théorique. La statistique D représente l'écart maximal absolu entre ces deux fonctions : une valeur faible indique un bon ajustement.
2. Le critère d'information d'Akaike (AIC) est une mesure de la qualité d'un modèle statistique qui arbitre entre la qualité de l'ajustement et la complexité du modèle. Il pénalise l'ajout de paramètres pour éviter le surapprentissage. Un AIC plus faible indique un meilleur modèle.
3. Le critère d'information bayésien (BIC) est similaire à l'AIC mais impose une pénalité plus forte pour le nombre de paramètres, dépendant de la taille de l'échantillon. Il tend à favoriser des modèles plus parcimonieux. Comme pour l'AIC, une valeur plus faible est préférable.
4. L'AIC et le BIC servent à comparer deux ajustements, pour savoir quel modèle est le mieux ajusté on va donc regarder le plus faible AIC/BIC

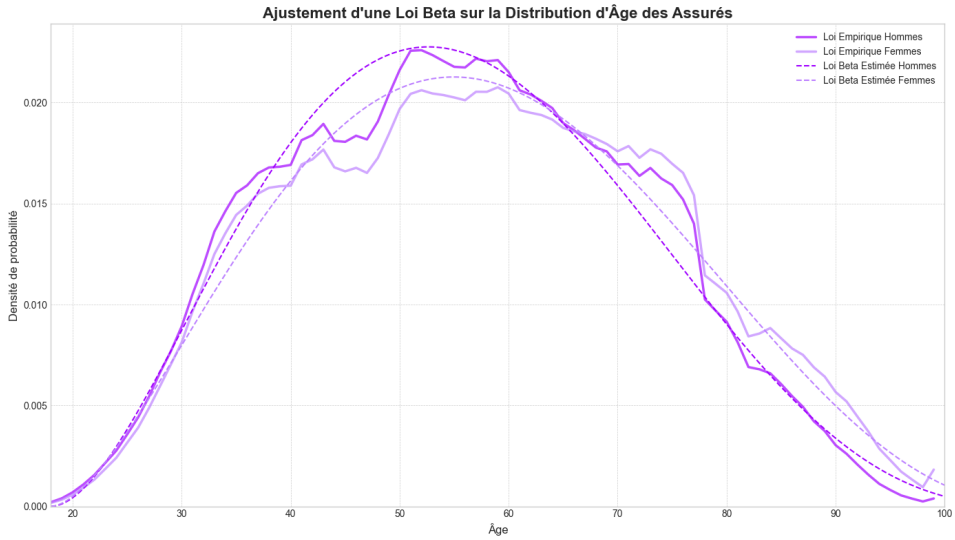

FIGURE 2.4 – Ajustement de la loi Beta sur la distribution empirique. TODO : Séparer une version homme et une femme et mettre en annexe

Le tableau 2.1 confirme cette observation. La loi Beta présente une statistique K-S inférieure (traduisant une distance maximale plus faible entre la distribution théorique et empirique) ainsi que des scores AIC et BIC plus bas, indiquant un meilleur ajustement global. C'est donc cette loi qui a été retenue pour modéliser l'âge des assurés dans le portefeuille synthétique.

Métrique	**Loi Gamma**	**Loi Beta**	**Meilleur Modèle**
Statistique K-S (D)	0.0396	0.0271	Beta
AIC (Akaike)	1 674 497	1 668 357	Beta
BIC (Bayésien)	1 674 527	1 668 378	Beta

TABLE 2.1 – Tableau comparatif des métriques d'ajustement (population masculine). TODO : mettre aussi les résultats pour la population féminine, mettre également des valeurs en gras

2.2.1.2 Modélisation de l'âge à la souscription

Une fois l'âge des assurés modélisé, il est indispensable de déterminer l'âge à la souscription. Cette variable est fondamentale, car elle permet de calculer l'ancienneté du contrat, un paramètre clé qui influence directement les lois de comportement, notamment les taux de rachat, dans les modèles de projection.

La distribution de l'âge à la souscription n'a pas été calibrée sur des données directes, mais a été dérivée de la courbe de taux de détention par âge, établie dans la section précédente. L'hypothèse sous-jacente est que la densité de probabilité de souscrire à un âge donné est proportionnelle à la vitesse à laquelle le taux de détention augmente à cet âge. Autrement dit, la distribution de l'âge à la souscription peut être approximée par la dérivée discrète de la fonction du taux de détention. Par exemple, une forte pente de la courbe de détention entre 25 et 35 ans signale une intense activité de souscription dans cette tranche

d'âge. En calculant la différence finie entre les points de la courbe interpolée, il est donc possible de construire une distribution empirique de l'âge à la souscription.

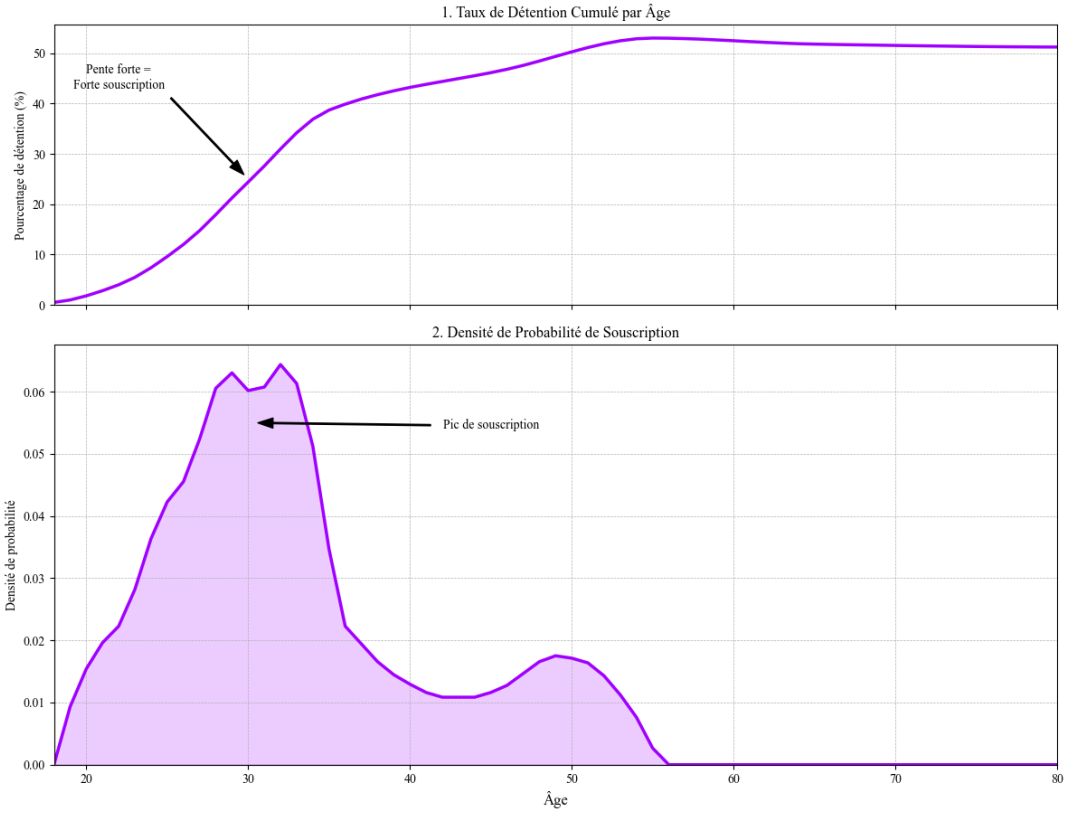

FIGURE 2.5 – Passage de la distribution empirique de l'âge à la souscription à la densité de probabilité du taux de souscription.

Plusieurs lois de probabilité ont été testées pour modéliser cette distribution empirique de l'âge à la souscription :

— La **loi Gamma** : définie sur $\mathbb{R}^+$, elle est souvent utilisée pour modéliser des durées. Sa densité est $f(x;k,\theta) = \frac{x^{k-1}e^{-\frac{x}{\theta}}}{\theta^k\Gamma(k)}$.

— La **loi Beta** : définie sur un intervalle borné $[a,b]$, elle offre une grande flexibilité de forme. Sa densité standard sur $[0,1]$ est $f(x;\alpha,\beta) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha,\beta)}$.

— La **loi de Weibull** : courante en analyse de survie, sa densité est donnée par $f(x;\lambda,k) = \frac{k}{\lambda}\left(\frac{x}{\lambda}\right)^{k-1} e^{-(x/\lambda)^k}$.

— Le **modèle de mélange gaussien (GMM)** : il s'agit d'une combinaison linéaire de plusieurs lois normales, permettant de s'ajuster à des distributions multimodales. Sa densité est $f(x) =$

$\sum_{i=1}^{K} w_i \frac{1}{\sigma_i \sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu_i}{\sigma_i}\right)^2}$.

Le tableau 2.2 présente les résultats.

Distribution	AIC	BIC	K-S (D)
GMM (n=2)	1 125 603	1 125 654	0.0485
Beta	1 385 454	1 385 495	0.0845
Gamma	1 400 178	1 400 208	0.1110
Weibull	1 437 176	1 437 207	0.1544

TABLE 2.2 – Tableau comparatif des métriques d'ajustement pour l'âge à la souscription. TODO : mettre également des valeurs en gras

Le **mélange gaussien à deux composantes (GMM)** s'est avéré être le modèle le plus performant, avec des scores AIC et BIC nettement inférieurs. Cela s'explique car 2 pics de souscription sont observables sur la distribution. Cette bimodalité, illustrée par la calibration de la loi GMM en figure 2.6, est une caractéristique de marché que les lois de probabilité plus simples ne peuvent capturer.

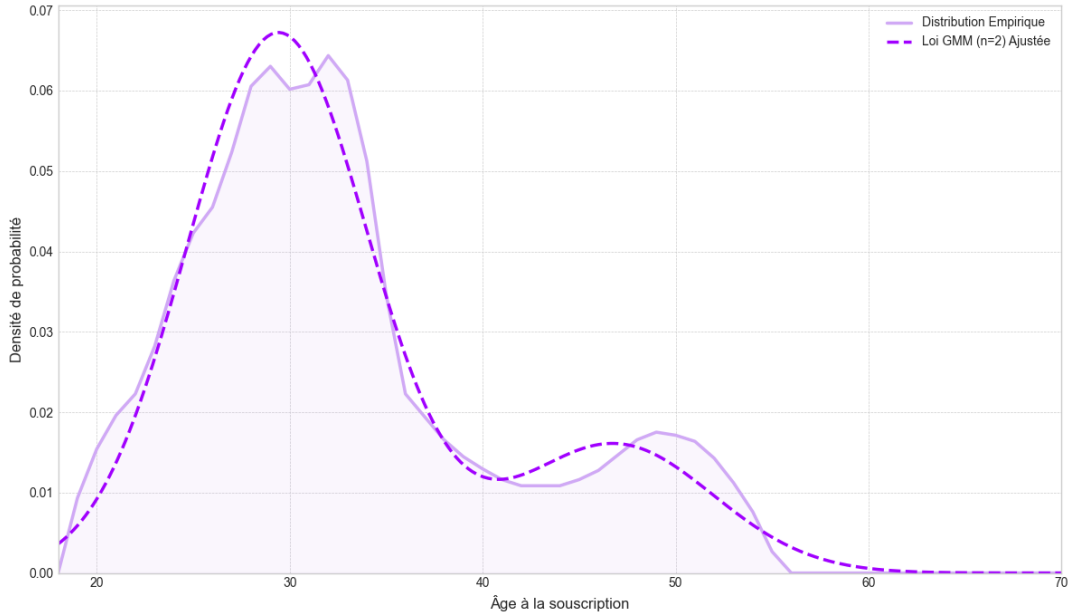

FIGURE 2.6 – Ajustement d'une GMM sur la distribution de l'âge à la souscription.

2.2.1.3 Modélisation de la (PM

Pour calculer la PM à partir des données marché, une méthode plus complexe a été mise en place. Une approche directe consistant à ajuster une loi sur des données de PM n'est pas possible car des données publiques sur ce sujet n'existent pas. Une méthodologie de modélisation conditionnelle a donc été mise en place.

L'hypothèse fondamentale est que la PM d'un individu est principalement fonction de son patrimoine, qui lui-même est fortement corrélé à son âge. La modélisation s'est donc déroulée en plusieurs étapes.

La première étape a consisté à modéliser la distribution du patrimoine brut en fonction de l'âge, en s'appuyant sur les données de l'INSEE [8]. Plutôt que de calibrer une seule loi pour toute la population, une **loi Lognormale** a été ajustée pour chaque tranche d'âge. Les paramètres de cette loi, μ et σ, ont été estimés par la méthode de **correspondance des quantiles**. Cette méthode est particulièrement adaptée lorsque les données individuelles ne sont pas disponibles et que seules des statistiques agrégées sont fournies. Elle consiste à déterminer les paramètres qui minimisent l'écart quadratique entre les quantiles théoriques de la loi et les quantiles empiriques observés (ici les déciles) :

$$(\hat{\mu}, \hat{\sigma}) = \arg\min_{\mu,\sigma} \sum_{i=1}^{9} \left(F^{-1}(p_i; \mu, \sigma) - Q_{emp}(p_i)\right)^2 \tag{2.2}$$

où $p_i \in \{0.1, \ldots, 0.9\}$, F^{-1} est la fonction quantile de la loi Lognormale et Q_{emp} les valeurs fournies par l'INSEE. Cette approche garantit que la distribution ajustée reproduit fidèlement la dispersion de la population réelle. Le tableau 2.3 synthétise les paramètres obtenus.

Tranche d'âge	μ	σ
Moins de 30 ans	9.9233	1.7713
30 à 39 ans	11.6750	1.8374
40 à 49 ans	12.1756	2.1221
50 à 59 ans	12.3216	2.0551
60 à 69 ans	12.3579	2.0772
70 ans ou plus	12.2620	1.8199

Table 2.3 – Paramètres de la loi Lognormale du patrimoine brut, calibrés par tranche d'âge.

Sur la base des calibrations précédentes, une population synthétique de 500 000 individus a été générée. Pour chaque individu, un âge a été tiré selon la loi Bêta déterminée précédemment, puis un patrimoine a été tiré selon la loi Lognormale conditionnelle correspondant à son âge. On obtient ainsi un échantillon de paires (Âge, Patrimoine) respectant la corrélation observée dans la réalité (TODO : rajouter un graphe 3D si c'est possible/lisible).

La deuxième étape consiste à estimer la part du patrimoine de chaque individu allouée à l'assurance-vie. Pour ce faire, les données de l'INSEE sur la composition du patrimoine par décile [8] sont utilisées. La figure 2.7 illustre la part du patrimoine financier en fonction du patrimoine brut moyen. Cette relation n'est pas linéaire. Pour les patrimoines les plus modestes, qui n'ont pas encore la capacité d'investir dans l'immobilier, la part des actifs financiers est relativement élevée. À mesure que le patrimoine augmente, une part significative est allouée à l'immobilier, ce qui diminue mécaniquement la part relative du patrimoine financier. Ce phénomène s'inverse cependant pour les patrimoines les plus élevés, où la diversification vers des actifs financiers redevient prépondérante, entraînant une remontée de leur part dans le patrimoine total, ce n'est pas observable sur le graphique 2.7 car les données sont agrégées par décile.

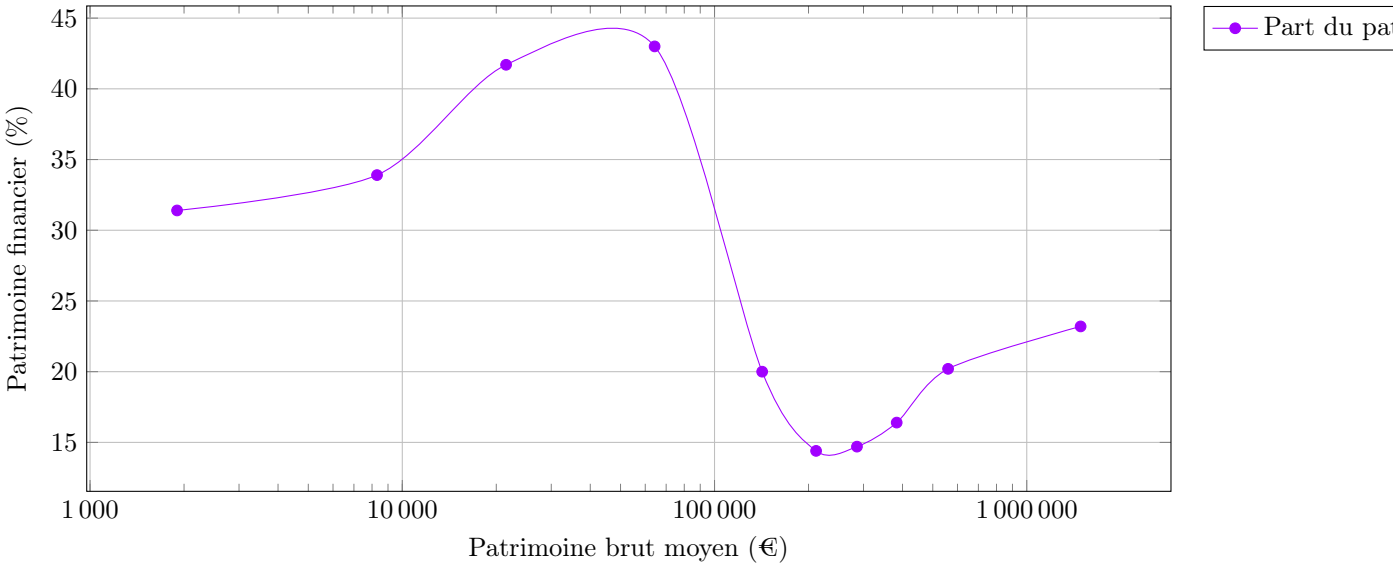

FIGURE 2.7 – Part du patrimoine financier en fonction du patrimoine brut moyen, par décile [8].

La troisième étape consiste à lier le patrimoine financier à la PM. Il est en effet plus réaliste de considérer que l'épargne en assurance-vie (ou la PM du point de vue de l'assureur) constitue une part du patrimoine financier plutôt que du patrimoine brut. Une hypothèse centrale est donc formulée : la PM d'un individu est estimée comme une fraction de son patrimoine financier. Sur la base de données INSEE [8], cette fraction est fixée à **40%**. Ainsi, pour chaque individu de la population simulée, la PM est calculée comme suit :

$$\text{PM} = \text{Patrimoine Brut} \times \text{Part du Patrimoine Financier} \times 40\% \tag{2.3}$$

Cette règle permet de transformer la distribution de patrimoine en une distribution de PM, en tenant compte des non-linéarités observées dans la composition du patrimoine.

Après avoir appliqué ce processus à toute la population simulée, nous obtenons un échantillon réaliste de Provisions Mathématiques. Une dernière calibration a montré que la distribution de ces PM pouvait être modélisée de manière très satisfaisante par une **loi Lognormale**. Bien que les tests d'adéquation classiques rejettent formellement l'hypothèse nulle en raison de la très grande taille de l'échantillon (rendant le test extrêmement sensible aux infimes déviations), l'analyse comparative des critères d'information et de la distance K-S confirme la supériorité de la loi Lognormale sur cet ajustement, comme l'indique le tableau 2.4.

Distribution	AIC	BIC	K-S (D)
Lognorm	7 142 088	7 142 120	0.017
Gamma	7 254 743	7 254 774	0.145

TABLE 2.4 – Pour le critère de Kolmogorov-Smirnov, la loi Lognormale est largement meilleure que la loi Gamma pour estimer cette distribution.

2.2.1.4 Modélisation des variables financières reliées à la revalorisation du passif : TMG, TAF et TFGSE

La détermination des taux minimums garantis par année de souscription s'appuie sur les plafonds réglementaires de taux techniques définis par le Code des assurances, tels qu'analysés dans la note « Le taux technique en assurance vie » publiée par l'ACPR [14],et les travaux de l'ACPR sur l'assurance vie en environnement de taux bas [15], complétés par la veille de marché de Good Value for Money sur les caractéristiques des contrats d'assurance vie [18].

La note [14] rappelle notamment que, depuis les années 1990, le taux technique maximal autorisable sur les contrats d'assurance vie est encadré par une formule fonction du taux moyen des emprunts d'État (TME), avec un plafond de l'ordre de 4,5 % au début des années 1990, puis une baisse progressive de ce plafond au fil de la diminution des taux d'intérêt. Les travaux ultérieurs de l'ACPR montrent qu'en environnement de taux bas, le taux technique moyen effectivement pratiqué sur le stock de contrats s'est progressivement rapproché de 0 %, passant d'environ 0,50 % au milieu des années 2010 [15] à 0,35 % sur la période récente [16].

Sur la base de ces éléments réglementaires et de marché, nous construisons une série historique de TMG par année de souscription. Pour chaque année t, nous retenons :

— un *taux technique maximal réglementaire* $TT_t^{\max}$, issu des plafonds ACPR/Code des assurances ;

— un TMG_t effectivement utilisé dans notre modèle, calibré en dessous de ce plafond, de façon à représenter un contrat typique de l'année considérée.

Le tableau 5.1 présente la série retenue pour la période 1993–2024.

On observe alors que, jusqu'au milieu des années 1990, les plafonds de taux techniques autorisent des TMG jusqu'à 4,5 %, ce qui est cohérent avec les niveaux de TMG donnés dans contrats de l'époque tels que décrits dans [14, 18]. À partir de la fin des années 1990 et des années 2000, la baisse des taux d'intérêt se traduit par une réduction progressive des plafonds réglementaires et des TMG pratiqués, les valeurs retenues TMG_t restant systématiquement inférieures à $TT_t^{\max}$ afin de tenir compte d'un certain conservatisme des assureurs.

À partir de 2015, nous faisons l'hypothèse de TMG nuls ($TMG_t = 0$) pour les nouveaux contrats, ce qui reflète l'environnement de taux durablement bas documenté par l'ACPR [15] et la généralisation des contrats d'épargne en assurance vie sans garantie explicite de taux (garantie limitée au capital net de frais, la performance étant portée par la participation aux bénéfices). Cette hypothèse est cohérente avec les analyses de marché montrant que, sur la période récente, la quasi-totalité des nouveaux contrats

d'épargne individuelle n'affichent plus de taux minimum garanti significatif [18].

Dans le cadre de la modélisation ALM présentée dans la suite, cette série annuelle de TMG constitue la base pour la construction de profils discrets par génération de contrat. Pour chaque année de souscription t, trois profils de contrat sont définis autour de TMG_t (un profil généreux, un profil médian et un profil conservateur), de façon à représenter la dispersion observée des TMG dans un même groupe tout en conservant un cadre de simulation discret adapté à l'agrégation de passifs.

Intégration du TAF et du TFGSE dans la modélisation des TMG

Au-delà du seul TMG_t, la valorisation des engagements en assurance vie dépend fortement des *frais de gestion prélevés sur les encours* et de la participation aux bénéfices effectivement redistribuée aux assurés. Pour capturer ces deux dimensions dans un cadre de modélisation discret, deux paramètres complémentaires sont introduits pour chaque contrat :

— le taux de frais de gestion sur encours $TFGSE$, appliqué annuellement sur la PM ;

— le taux d'affectation des produits financiers TAF, représentant la part des produits financiers attribuée aux assurés (taux servi et dotation à la provision pour participation aux bénéfices).

Les données de marché publiées par France Assureurs [19] sur l'assurance vie en unités de compte montrent qu'en 2024, les frais de gestion sur encours des contrats en unités de compte s'élèvent en moyenne à 0,88 % par an, avec une valeur de 0,83 % pour les gestions libres ou pilotées. Pour les supports en euros, les mêmes travaux indiquent un taux de frais de gestion d'environ 0,66 % par an, ce qui situe la moyenne de marché entre 0,6 % et 0,7 % selon le type de contrat. Ces ordres de grandeur sont cohérents avec les comparatifs de frais publiés par différents acteurs de place, qui situent la plupart des contrats dans une fourchette de 0,5 % à 1,0 % de frais de gestion annuels sur encours.

Dans le modèle, afin de rester cohérent avec cette distribution observée tout en conservant une structure discrète, l'approche retenue s'appuie sur les pratiques tarifaires documentées de contrats patrimoniaux de référence (comme le contrat Cachemire 2 Serie 2 de La Banque Postale [20]). Trois niveaux de $TFGSE$ sont ainsi définis :

$$TFGSE \in \{0{,}60\,\%,\ 0{,}70\,\%,\ 0{,}85\,\%\}.$$

Ces trois valeurs représentent respectivement :

— un profil haut de gamme (0,60 %), typique des contrats de gestion privée très compétitifs ;

— un profil moyen (0,70 %), proche de la moyenne observée sur les fonds en euros et caractéristique des gammes patrimoniales ;

— un profil standard (0,85 %), représentant des contrats grand public avec une structure de frais plus classique.

Dans chaque groupe d'année t, la probabilité d'appartenance à l'un de ces trois profils est ajustée de manière à ce que la moyenne pondérée de $TFGSE$ reste compatible avec les statistiques agrégées de marché, tout en reflétant une amélioration progressive des grilles tarifaires sur les générations récentes

de contrats.

Concernant la participation aux bénéfices, le cadre réglementaire français (Code des assurances) impose aux organismes d'assurance vie une redistribution minimale. Celle-ci correspond à 85 % du solde du compte financier et à 90 % du solde du compte technique, allouée sous forme de revalorisation immédiate ou de dotation à la PPE. Dans la pratique, en raison des enjeux concurrentiels, il est observé que la part des résultats financiers effectivement redistribuée aux assurés excède régulièrement ces minima légaux. Les études de l'ACPR sur la revalorisation des contrats mettent en évidence une contrainte forte sur les marges conservées par les assureurs, le taux de redistribution dépassant fréquemment le seuil réglementaire pour s'aligner sur les attentes du marché [15, 16].

Cette réalité est modélisée au moyen d'un taux d'affectation des produits financiers, noté TAF, de nature discrète, qui représente la part des produits financiers attribuée aux assurés sur un exercice donné. Afin de respecter le seuil légal de distribution de la marge financière, trois niveaux sont retenus :

$$TAF \in \{85\,\%,\ 90\,\%,\ 95\,\%\}.$$

Ces niveaux correspondent à :

— 85 % : un comportement correspondant au plancher réglementaire, associé à des contrats standardisés ou peu généreux en termes de participation aux bénéfices ;

— 90 % : un comportement moyen de marché, cohérent avec les constats de l'ACPR sur des marges techniques modérées ;

— 95 % : un profil particulièrement favorable aux assurés, typique de certains contrats haut de gamme ou de gammes associatives affichant des taux servis durablement supérieurs à la moyenne du marché.

Pour assurer la cohérence économique du modèle, une dépendance entre le $TFGSE$ et le TAF est introduite au travers de profils de contrats. Concrètement, pour chaque contrat synthétique, il est procédé au tirage d'un profil de frais parmi $\{0{,}60\,\%,\ 0{,}70\,\%,\ 0{,}85\,\%\}$, puis d'un niveau de TAF parmi les trois valeurs $\{85\,\%,\ 90\,\%,\ 95\,\%\}$, au moyen d'une loi discrète conditionnelle. Par exemple, un contrat à faibles frais ($TFGSE = 0{,}60\,\%$) présente une probabilité plus forte d'être associé à un TAF élevé (95 %), tandis qu'un contrat fortement chargé ($TFGSE = 0{,}85\,\%$) se voit plus souvent associé à un TAF fixé sur le plancher légal (85 %). Ce couplage reproduit qualitativement le fait que les contrats les plus compétitifs en frais sont également ceux qui, historiquement, affichent les meilleurs taux servis et une politique de PB plus favorable aux assurés.

Au total, pour une année de souscription t donnée, chaque contrat du portefeuille synthétique se trouve donc caractérisé par un triplet discret $(TMG_t, TFGSE, TAF)$, où :

— Le TMG_t est fixé par la table historique de la section précédente, construite à partir des plafonds de taux techniques de l'ACPR ;

— Le $TFGSE$ prend l'une des trois valeurs $\{0{,}60\,\%,\ 0{,}70\,\%,\ 0{,}85\,\%\}$;

— Le TAF prend l'une des trois valeurs $\{85\,\%,\ 90\,\%,\ 95\,\%\}$.

Ce choix de discrétisation permet de simplifier la génération du portefeuille sur les aspects financiers et assurantiels tout en restant ancré sur des ordres de grandeur observés sur le marché français de l'assurance vie, tels que documentés par France Assureurs et l'ACPR.

Corrélation des caractéristiques contractuelles avec la provision mathématique

Afin de refléter fidèlement la structure du portefeuille d'un assureur français, une dépendance est introduite entre les paramètres contractuels et la PM du contrat. Cette dernière constitue une manière simple de segmenter les contrats par gamme commerciale (Standard, Patrimonial, Gestion privée).

Cette approche s'appuie sur des observations de marché : selon l'hypothèse prise précédemment, les $TFGSE$ sont structurellement dégressifs avec l'encours du contrat. À titre d'illustration, les conditions générales de contrats patrimoniaux de référence définissent explicitement une réduction des frais de gestion annuels dès lors que l'encours franchit certains seuils, typiquement 200 000 € et 500 000 € [20, 19]. Les contrats présentant des encours importants se concentrent ainsi dans les gammes patrimoniales et de gestion privée, lesquelles affichent par ailleurs des politiques de participation aux bénéfices et des taux minimums garantis différenciés par rapport aux contrats de la clientèle grand public.

Définition des seuils de provision mathématique

Les contrats sont segmentés selon trois tranches de provision mathématique PM_k :

Table 2.5 – Segmentation des contrats selon la PM

Gamme commerciale (Typologie)	**Tranche** PM_k
Standard (Clientèle grand public)	$PM_k \leq 200\,000$ €
Patrimonial (Clientèle aisée et haut de gamme)	200 000 € $< PM_k \leq 500\,000$ €
Gestion privée (HNWI [5], Family offices [6])	$PM_k > 500\,000$ €

Ces seuils s'inspirent directement de la segmentation commerciale standard appliquée par les grands acteurs de la place, telle qu'illustrée par les paliers tarifaires des contrats patrimoniaux de référence [20]. Cette stratification permet de générer un portefeuille synthétique dont la structure de frais agrégée s'avère cohérente avec les moyennes documentées par France Assureurs [19].

Lois conditionnelles par tranche de provision

La distribution croisée exacte de ces caractéristiques n'étant pas publiquement disponible à une maille individuelle, la matrice des probabilités a été calibrée pour ce mémoire. Ce calibrage répond à un double objectif :

1. Traduire mathématiquement la dynamique concurrentielle observée : la gamme Standard est massivement orientée vers la tarification la moins favorable, tandis que la gestion privée se voit attribuer majoritairement les conditions optimales.

5. High Net Worth Individuals : Personnes possédant plus de 1 million d'euros de patrimoine.
6. Family offices : Structures de gestion patrimoniale pour des familles fortunées.

2. Garantir que les moyennes pondérées finales du portefeuille synthétique convergent vers les statistiques de marché (notamment un $TFGSE$ moyen avoisinant les 0,70 %).

Pour chaque contrat généré, après le tirage de l'année t et de la provision mathématique PM_k, les paramètres $(TFGSE, TAF)$ sont ainsi affectés selon la loi conditionnelle suivante :

Table 2.6 – Lois discrètes conditionnelles de $(TFGSE, TAF)$ selon la tranche de PM

Gamme	**Tranche** PM_k	**Probabilités** $\mathbb{P}(TFGSE, TAF \mid PM_k)$ (0,60 %, 95 %)	(0,70 %, 90 %)	(0,85 %, 85 %)
Standard	$PM_k \leq 200$ k€	0,10	0,30	0,60
Patrimonial	200 k€$< PM_k \leq 500$ k€	0,30	0,50	0,20
Gestion privée	$PM_k > 500$ k€	0,70	0,25	0,05

Le TMG reste fonction de l'année t uniquement (TMG_t de la table 5.1). Toutefois, la pondération des générations anciennes (aux TMG plus élevés) s'avère naturellement plus forte dans les tranches de gestion privée, l'accumulation des provisions nécessitant mécaniquement une antériorité plus longue du contrat.

Algorithme de génération mis à jour

L'algorithme de génération du portefeuille s'établit de la façon suivante :

1. Tirage de l'année de souscription $t \in [1993, 2024]$ selon la structure d'âge du portefeuille ;
2. Tirage de la provision mathématique PM_k (loi log-normale typique des encours d'assurance vie) ;
3. Identification de la tranche de PM_k et affectation du couple $(TFGSE, TAF)$ selon la table 2.6 ;
4. Assignation du TMG_t selon la table historique .

Vérification de cohérence avec les données agrégées

Cette structure assure plusieurs cohérences observables :

— **TFGSE moyen** : la moyenne pondérée par les tranches de PM_k retombe autour de 0,65 % à 0,70 %, ce qui est cohérent avec les données de France Assureurs (fonds euros : 0,66 %) [19].

— **TMG moyen** : les contrats anciens ($TMG > 2$ %) se trouvent naturellement plus représentés dans les tranches à forte PM_k. Cette mécanique permet d'obtenir un taux technique moyen sur le portefeuille simulé compris entre 0,35 % et 0,50 %, un niveau parfaitement conforme aux moyennes successives rapportées par l'ACPR (de 0,51 % en 2015 à environ 0,35 % sur la période récente) [15, 16].

— **Relation frais-rendement** : les contrats de gestion privée présentent à la fois des frais plus bas et un TAF plus élevé, reproduisant le différentiel de performance observé entre les gammes.

Cette approche par corrélation avec la PM permet ainsi de générer un portefeuille synthétique dont les caractéristiques par contrat s'avèrent cohérentes avec les statistiques économiques publiées, tout en

conservant une structure parfaitement discrète et donc compatible avec l'agrégation ALM.

2.2.1.5 Modélisation de l'allocation entre fonds en euros et unités de compte

La répartition de la PM entre le fonds en euros et les supports en UC est une caractéristique essentielle pour modéliser un portefeuille d'assurance vie et pour mener à bien les analyses de sensibilités financières dans la suite de ce mémoire.

Cependant, les données publiques fournissent principalement des statistiques agrégées. À titre d'exemple, la part des UC dans la collecte s'établit historiquement autour de 40 % sur le marché français [1, 19]. Si ces publications renseignent sur les profils de risque types, elles ne donnent en revanche aucun accès à la répartition économique spécifique contrat par contrat. En l'absence de données individuelles permettant d'estimer un modèle statistique classique, une approche paramétrique a donc été retenue, calibrée pour reproduire fidèlement ces grands équilibres observés sur le marché.

Spécification du modèle d'allocation

L'objectif est de modéliser la proportion $p_{\mathrm{UC},i} \in (0,1)$ de la PM investie en unités de compte pour chaque contrat i. Dans le cadre de cette approche paramétrique, ce modèle repose sur un prédicteur linéaire η_i combinant les caractéristiques du contrat et de l'assuré.

Le choix des variables explicatives retenues s'appuie sur les deux principaux facteurs comportementaux d'un contrat d'assurance vie :

— **L'âge de l'assuré ($\mathbf{Age}_i$)** : L'aversion au risque s'accentue généralement avec l'âge, les épargnants privilégiant la sécurisation de leur capital sur le fonds en euros à l'approche de la retraite.

— **Le volume de l'épargne ($\log(\mathbf{PM}_i)$)** : Il traduit un effet richesse. Les encours les plus importants présentent souvent une part d'UC plus élevée, traduisant une recherche de diversification et une meilleure capacité à absorber la volatilité. L'utilisation du logarithme s'avère indispensable pour atténuer la forte asymétrie de la distribution des encours et linéariser cet effet.

Par souci de parcimonie, il a été décidé de faire une modélisation restreinte à deux variables explicatives [7]. La combinaison linéaire de ces effets se traduit par l'équation suivante :

$$\eta_i = \beta_0 + \beta_{\mathrm{age}}\,\mathrm{Age}_i + \beta_{\mathrm{pm}}\,\log(\mathrm{PM}_i) \tag{2.4}$$

7. L'intégration initiale de l'ancienneté du contrat a été écartée suite aux premiers tests de calibration. Le coefficient obtenu s'avérant proche de zéro et de signe contraire aux attentes, cette variable présentait une trop forte colinéarité avec l'âge de l'assuré. Les détails de cette première calibration sont présentés en Annexe 5.3.

Afin de garantir que la proportion modélisée reste strictement bornée entre 0 et 1, une spécification de type *Logit*[8] a été implémentée. La part investie en unités de compte est ainsi obtenue par la transformation logistique :

$$p_{\mathrm{UC},i} = \frac{1}{1 + \exp(-\eta_i)} \tag{2.5}$$

La part investie en fonds en euros s'en déduit naturellement par la relation $p_{\mathrm{Euro},i} = 1 - p_{\mathrm{UC},i}$.

Hypothèses économiques et calibration

Faute de données individuelles complètes permettant une estimation par maximum de vraisemblance, les coefficients ont été calibrés par une méthode de *matching de moments*[9]. Cette technique d'optimisation a consisté à ajuster les coefficients β pour que le portefeuille simulé atteigne la cible macroéconomique globale (établie à 40 % d'UC), tout en forçant le modèle à respecter des points de contrôle locaux.

En l'absence de base de données publique croisant l'âge et la part d'UC contrat par contrat, ces points de contrôle ont été définis à dire d'expert. Ils représentent des profils types d'assurés construits pour refléter les standards de la gestion de patrimoine et les politiques commerciales actuelles des assureurs français :

— Les jeunes assurés, disposant d'un horizon de placement long, sont orientés vers des profils dynamiques (forte part d'UC).

— À l'inverse, les assurés d'âge avancé s'inscrivent dans une logique de sécurisation du capital en vue de la transmission, ce qui se traduit par une prédominance écrasante du fonds en euros.

Ces profils de contrôle, qui ont servi de points d'ancrage pour l'algorithme d'optimisation, sont détaillés dans le Tableau 2.7 :

Table 2.7 – Profils types (à dire d'expert) utilisés pour la calibration du modèle

Profil	Âge (ans)	PM (k€)	Part UC Cible (%)
1 (Dynamique)	30	10	60
2 (Équilibré+)	45	150	50
3 (Prudent)	70	50	25
4 (Sécurisation)	85	200	15

METTRE A JOURS LES VALEURS ET REFAIRE TOURNER SANS L'ANCIENNETE Après calibration, les coefficients obtenus pour ce modèle sont les suivants : $\beta_0 = 1.0039$, $\beta_{\mathrm{age}} = -0.0424$ et $\beta_{\mathrm{pm}} = 0.0746$. La part moyenne d'UC obtenue sur le portefeuille généré est de 39.98 %, confirmant la parfaite atteinte de l'objectif global.

Les paramètres β_j du modèle reflètent rigoureusement les faits stylisés attendus :

8. Le modèle Logit s'appuie sur une fonction de transformation projetant l'ensemble des réels vers l'intervalle $(0, 1)$. Il s'agit d'un standard actuariel pour la modélisation des proportions et des probabilités.

9. La méthode de matching de moments consiste à égaliser les moments théoriques d'une distribution avec leurs équivalents observés ou ciblés. Dans notre cas, il s'agit de trouver les paramètres permettant de reproduire la moyenne globale du marché et des points de passage locaux.

— **Aversion au risque et âge ($\beta_{\mathbf{age}} = -0.0424$)** : Comme attendu (signe négatif), la part d'UC décroît avec l'âge de l'assuré, traduisant la volonté de sécurisation progressive du patrimoine.

— **Capacité d'absorption du risque et richesse ($\beta_{\mathbf{pm}} = 0.0746$)** : Conformément aux observations de marché (signe positif), les encours les plus importants sont associés à une plus forte diversification, augmentant mécaniquement la part d'UC.

Bien que cette spécification logistique paramétrique constitue une simplification de la réalité, elle fournit une décomposition économiquement cohérente de la PM pour chaque assuré simulé. Cette méthode permet ainsi de doter le portefeuille synthétique de profils d'allocation réalistes et différenciés, une condition *sine qua non* pour garantir la pertinence des analyses de sensibilités financières menées dans la suite de ce mémoire.

2.2.1.6 Ajout du sexe pour finaliser le portefeuille

Pour finaliser le portefeuille, le sexe est une variable important à modéliser. Il est généré aléatoirement selon une loi de Bernoulli, calibrée sur la répartition hommes/femmes observée dans la population des assurés. En France, les données de l'INSEE indiquent que la répartition est légèrement en faveur des femmes, avec environ 52 % de femmes et 48 % d'hommes parmi les assurés en assurance vie [9]. Cette répartition est donc utilisée pour générer le sexe de chaque individu du portefeuille synthétique, en tirant une variable binaire où $P(Sexe = Femme) = 0.52$ et $P(Sexe = Homme) = 0.48$.

Ce processus itératif permet de générer un portefeuille synthétique de 1 000 000 contrats présentant des caractéristiques statistiques fidèles à la réalité du marché français, prêt à être utilisé pour les étapes d'agrégation.

2.2.2 Synthèse et génération du portefeuille final

L'étape finale de la modélisation consiste à assembler les différentes distributions marginales et conditionnelles calibrées précédemment pour générer le portefeuille de passifs complet. Contrairement à une approche purement multivariée (copule globale 3D) qui peinerait à capturer la nature conditionnelle de la richesse par rapport à l'âge, une approche hybride a été implémentée.

2.2.2.1 Modélisation de la dépendance des âges par copule

L'analyse des données montre une corrélation mécanique et comportementale entre l'âge de l'assuré et son âge à la souscription. Pour reproduire cette structure de dépendance sans figer les distributions marginales, une **copule gaussienne bivariée** a été utilisée.

Cette copule permet de générer des paires de rangs corrélés $(u, v) \in [0, 1]^2$ avec un paramètre de corrélation de Spearman calibré à $\rho = 0.7$. Ces rangs sont ensuite transformés en valeurs réelles via les fonctions quantiles inverses (PPF) des lois marginales retenues :

— $Age_{assure} = F^{-1}_{Beta}(u)$

— $Age_{souscription} = F_{GMM}^{-1}(v)$

Une contrainte métier stricte est appliquée post-génération : l'âge à la souscription doit nécessairement être inférieur ou égal à l'âge actuel de l'assuré ($Age_{souscription} \leq Age_{assure}$). Les paires ne respectant pas cette condition sont rejetées et régénérées, assurant ainsi la cohérence temporelle des contrats.

2.2.2.2 Algorithme global de génération en cascade

Une fois l'âge et la date de souscription fixés via la copule bivariée, le reste des caractéristiques du contrat est généré de manière conditionnelle. L'algorithme final s'applique contrat par contrat selon les étapes suivantes :

1. **Génération du patrimoine global :** Pour l'âge de l'assuré, un montant de patrimoine brut est tiré aléatoirement dans la loi Lognormale spécifique à sa tranche d'âge.
2. **Test de détention et calcul de la PM :** Une épreuve de Bernoulli détermine la détention d'une assurance vie. Pour les détenteurs, la PM est calculée par application du ratio financier cible (40 % du patrimoine financier).
3. **Assignation de la gamme et des paramètres financiers :** En fonction de la PM générée, le contrat est classé dans un segment (Mass Market, Patrimonial, Gestion privée). Les taux de frais (TFGSE) et d'affectation (TAF) sont ensuite tirés selon la loi conditionnelle définie au tableau 2.6. Le TMG est lui déduit de l'année de souscription.
4. **Allocation Euro/UC :** À l'aide du modèle Logit calibré sur l'âge, l'ancienneté et la PM, la part investie en unités de compte est déterminée.
5. **Finalisation :** Le sexe de l'assuré est généré aléatoirement (52 % de femmes).

Cette séquence garantit que chaque ligne du portefeuille d'un million de contrats présente une cohérence interne parfaite, liant l'histoire de l'assuré (âge, date d'entrée) à sa richesse (PM) et aux caractéristiques de son produit (Frais, TMG, UC).

2.2.3 Hypothèses de projection et paramétrage ALM

Afin de rendre ce portefeuille synthétique exploitable par le modèle ALM, un cadre d'hypothèses actuarielles et financières a été décidé. La date de lancement des projections est fixée au 31 décembre 2024. Le périmètre d'étude est modélisé en *run-off* (portefeuille fermé), excluant de fait la projection de la production nouvelle et des primes futures régulières, par souci d'isolement des risques existants.

Sur le plan biométrique, le provisionnement et la sinistralité s'appuient sur l'application stricte des tables de mortalité réglementaires françaises prospectives (TG05 et TF05).

Enfin, la modélisation de la participation aux bénéfices et de la revalorisation du fonds Euro nécessite de définir une allocation d'actifs de référence. Celle-ci a été calibrée selon une structure standard de marché via l'étude de plusieurs SFCR [10]. Cette allocation vise alors à équilibrer rendement et sécurité : 80 % d'obligations, 15 % d'actions et 5 % d'immobilier chiffres à revoir. Cet environnement de projection

10.

permet de garantir que les variations d'indicateurs (BE, SCR) observées ultérieurement proviendront exclusivement de l'aggrégation des données ou des chocs de sensibilités appliqués.

2.3 Présentation du portefeuille de référence généré

2.3.1 Analyse descriptive et évaluation critique du passif

L'exécution de l'algorithme de génération a permis de constituer un portefeuille synthétique d'un million de contrats, représentant un encours total de 222, 09 milliards d'euros (montant uniquement associé à la PM des fonds Euro). L'analyse détaillée de ses caractéristiques est une étape préalable indispensable. Elle permet non seulement de valider la cohérence des hypothèses de modélisation, mais surtout d'identifier les zones de risques (concentration, liquidité) qui émergent alors de ce portefeuille.

2.3.1.1 Volumétrie, asymétrie extrême et limites de modélisation

La caractéristique la plus marquante de ce portefeuille est la surreprésentation des contrats avec des gros encours (supérieurs à 500 k€). L'analyse par gamme commerciale révèle une véritable asymétrie :

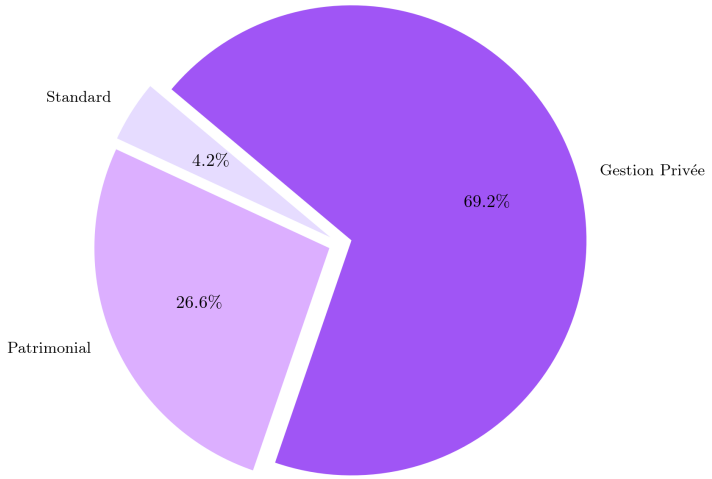

FIGURE 2.8 – Répartition des encours totaux par Gamme commerciale.

Le segment standard (PM $\leq 50\,k$€) représente la majorité absolue des polices (57 %), mais ne pèse que pour 4,2 % des encours totaux. À l'inverse, la clientèle de Gestion Privée (PM $> 500\,k$€) ne rassemble que 7,9 % des assurés mais capte plus de 69 % de la PM globale, avec une moyenne avoisinant 1,93 million d'euros par contrat. Ce qui est une concentration extrême pour un portefeuille d'assurance vie classique.

Cette concentration est formellement quantifiée par la courbe de Lorenz [11] :

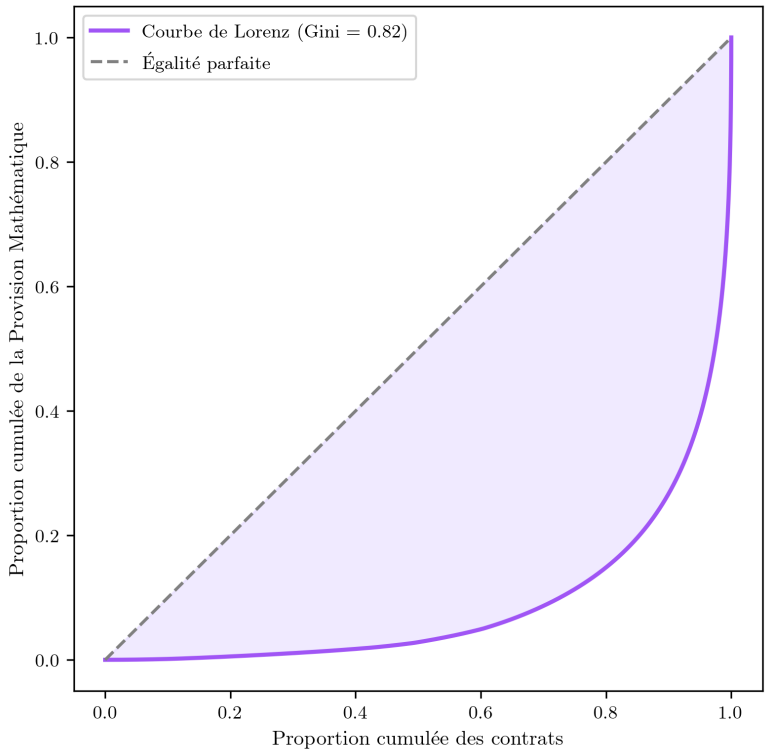

FIGURE 2.9 – Courbe de Lorenz de la PM et indice de Gini.

Avec un indice de Gini [12] s'élevant à $0,820$, le portefeuille présente une inégalité de répartition extrême. A titre de comparaison, en France, les inégalités de niveau de vie avaient un indice de Gini de 0.298 en 2018 [21]. D'un point de vue critique, ce phénomène illustre une limite inhérente aux hypothèses de génération utilisées. Le modèle postule que la PM découle d'une règle proportionnelle stricte :

$$\text{PM} = \text{Patrimoine Brut} \times \text{Part Financière} \times 40\,\% \tag{2.6}$$

Si cette formule est pertinente pour les segments grand public et patrimoniaux, elle devient obsolète pour les plus riches (queues de distribution de la loi log-normale), qui diversifient massivement leurs investissements (immobilier d'entreprise, *private equity*) et ne logent pas mécaniquement 40 % de leur richesse sur un contrat d'assurance vie.

Malgré ce biais, cette asymétrique constitue un bon cas d'usage de *stress-test* pour l'agrégation. En effet, S2, le *SCR Rachat Massif* sera dicté par cette minorité de très gros contrats. Une méthode de partitionnement déterministe classique lisserait ce segment à l'excès et il sera alors pertinent de trouver une méthode pour bien rassembler ce type de contrats.

11. La courbe de Lorenz est un outil graphique utilisé principalement pour représenter la répartition de la richesse (ici des encours dans un portefeuille).
12. L'indice de Gini est une mesure de l'inégalité de répartition, variant entre 0 (égalité parfaite) et 1 (inégalité maximale).

2.3.1.2 Profil démographique, liquidité fiscale et biais de survivance

La dynamique démographique et temporelle du passif détermine l'exposition au risque de longévité et de rachat structurel. L'âge moyen des assurés s'établit à $53,1$ ans comme le montre la figure 2.10, une valeur relativement centrée et cohérente avec le marché français.

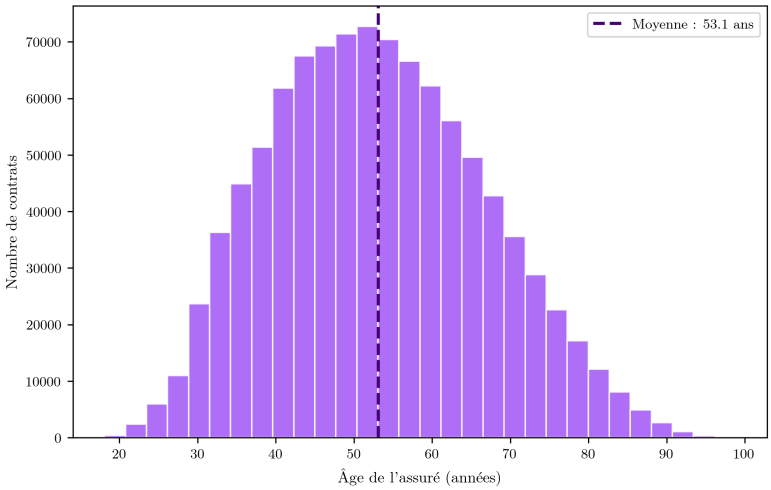

FIGURE 2.10 – Distribution de l'âge des assurés.

Cependant, l'analyse de l'ancienneté des contrats met en lumière une autre singularité majeure de la base de données :

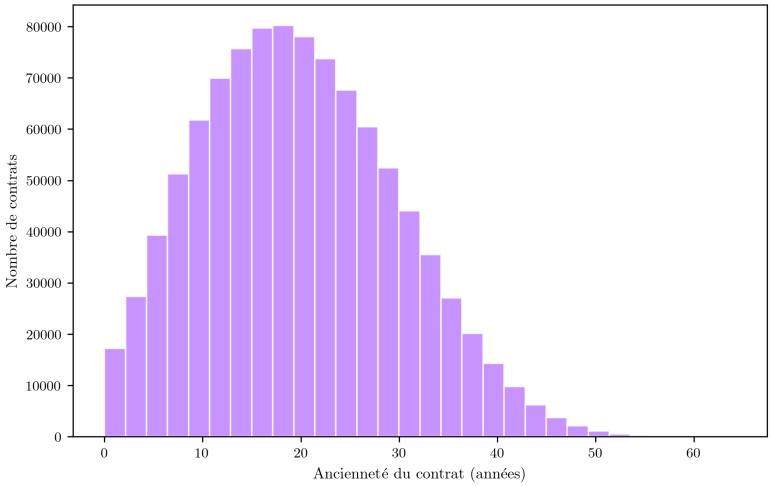

FIGURE 2.11 – Distribution de l'ancienneté des contrats.

L'ancienneté moyenne atteint $19,8$ ans. Visuellement, la distribution ne traduit aucune cassure autour de la huitième année, date anniversaire qui marque pourtant historiquement un pic de rachats suite à l'optimisation de la fiscalité pour les contrats en France.

Ce phénomène s'explique par un biais de survivance dans la méthode de génération. Les polices ont été créées en dérivant l'âge à la souscription depuis l'âge actuel, sans simuler l'historique d'écoulement du passif. En omettant l'application des lois de mortalité et les lois de rachats sur les deux dernières décennies, le portefeuille naît directement avec son volume actuel.

La conséquence directe sur la modélisation ALM est une liquidité écrasante des encours :

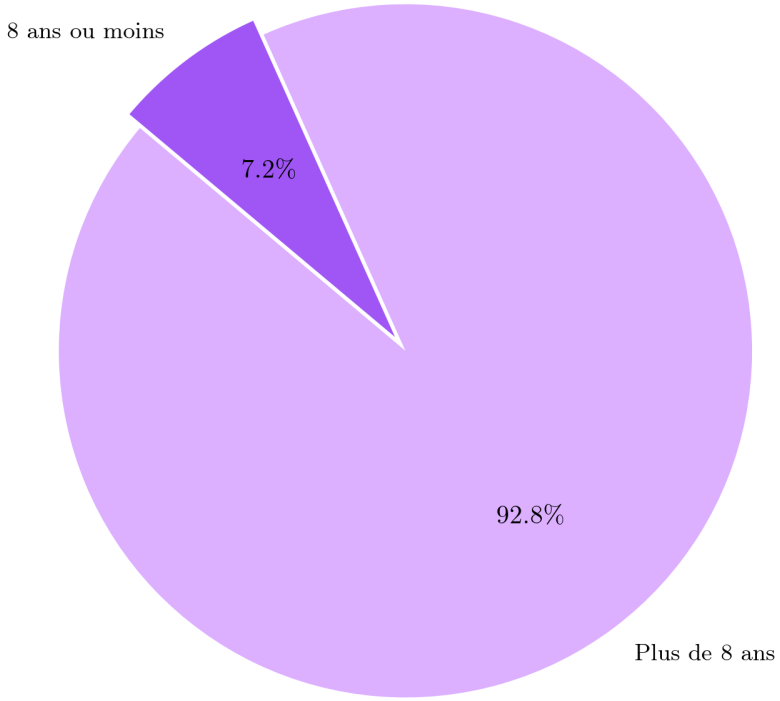

FIGURE 2.12 – Proportion des encours selon la maturité fiscale.

Près de $92,8\,\%$ des capitaux ont franchi le cap des 8 ans et sont affranchis de pénalités fiscales. Le frein contractuel à la sortie est donc quasi nul. En cas de choc de taux à la hausse, une fonction de rachat conjoncturel serait alors sollicitée à son maximum.

Pour appréhender la géométrie de ce risque croisé, la visualisation spatiale de l'intensité financière globale (les encours cumulés) selon l'âge et l'ancienneté s'avère extrêmement pertinente :

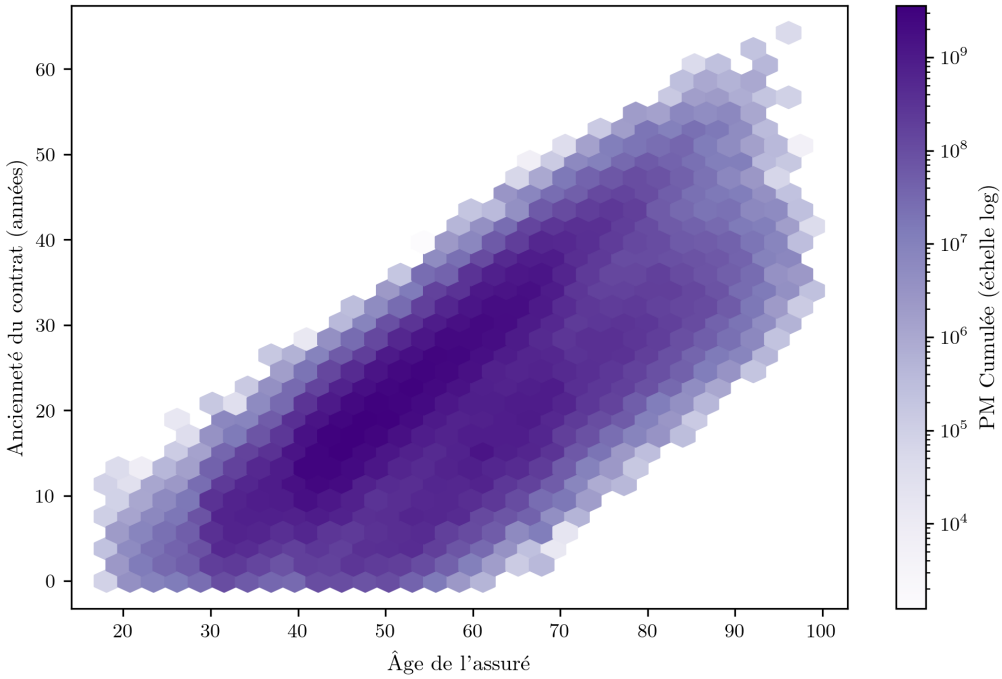

FIGURE 2.13 – Densité spatiale des encours cumulés selon le couple Âge / Ancienneté (échelle logarithmique).

Cette carte de chaleur met en évidence la concentration hétérogène des capitaux (les zones les plus denses regroupant la majorité de la PM). C'est précisément dans cet espace bidimensionnel très polarisé que les futurs algorithmes de *clustering* devront concentrer leurs *cluters* pour éviter de lisser le risque.

Sur le plan de la modélisation ALM et des exigences S2, le couple Âge-Ancienneté est le moteur principal de la dynamique du passif. L'âge pilote à la fois la mortalité et l'allocation Euro/UC. L'ancienneté, quant à elle, régit presque exclusivement la fonction de rachat, en définissant la liquidité fiscale du contrat. Toute erreur de lissage dans ces zones denses déformerait les lois de comportements non-linéaires des assurés, entraînant une mauvaise évaluation du *Best Estimate*.

2.3.1.3 Comportements financiers : Allocation et politique de frais

L'exposition aux risques de marché est rythmée par l'allocation des encours. La part globale investie sur les fonds Euro s'élève à 55,88 %. L'analyse croisée par âge démontre la pertinence des comportements simulés :

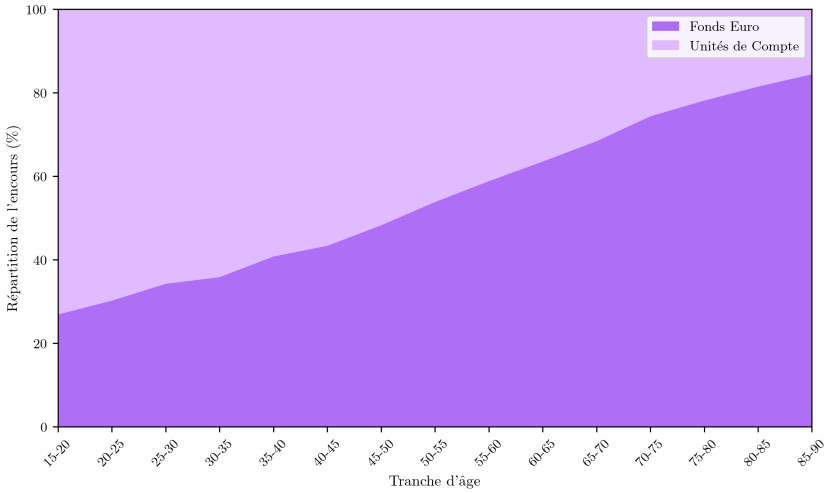

FIGURE 2.14 – Évolution de l'allocation entre Fonds Euro et Unités de Compte en fonction de l'âge.

La figure 2.14 traduit le mécanisme classique de sécurisation de l'épargne. Plus l'assuré vieillit, plus il arbitre ses encours vers le fonds Euro garanti, au détriment de la volatilité des UC. Préserver cette dynamique de désensibilisation lors de l'agrégation sera un critère important.

Du point de vue du passif en fonds Euro, le TMG moyen est à $1,88\,\%$. Cela est dû à la très forte ancienneté du contrat. Enfin, la politique de prélèvement choisie respecte bien les 3 paliers de frais choisis lors de la modélisation :

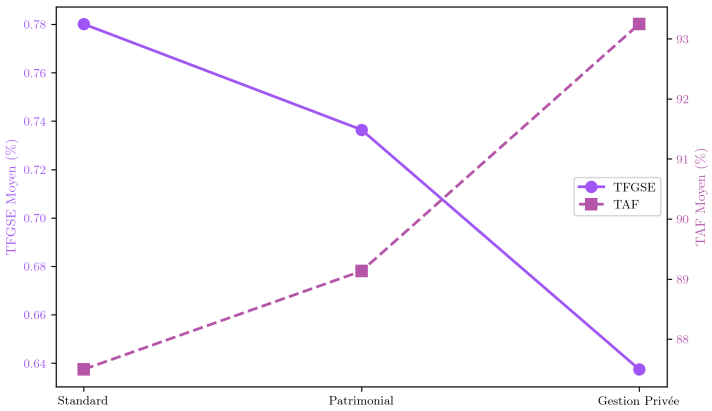

FIGURE 2.15 – TFGSE et TAF moyens par gamme.

Le TFGSE moyen est de $0,67\,\%$. La figure 2.15 illustre une dégressivité des frais : les contrats de la gestion privée bénéficient de tarifs plus avantageux que la gamme standard, tout en captant potentiellement un meilleur niveau de redistribution (TAF). Ce phénomène, conforme à la réalité du marché, traduit la volonté commerciale de fidéliser les patrimoines les plus rémunérateurs en volume, renforçant encore le poids stratégique de ce segment dans les projections futures.

Chapitre 3

Présentation des méthodes d'agrégation candidates

Après avoir établi le cadre réglementaire et construit un générateur de passif capable de produire des données réalistes, il convient désormais d'aborder la problématique centrale de ce mémoire : la réduction de la dimension du portefeuille de passif.

La projection individuelle de chaque contrat au sein des modèles ALM requiert des ressources computationnelles excessives ; l'agrégation du passif s'impose donc comme une nécessité technique pour les assureurs. Cette nécessité découle directement des exigences de réactivité lors des phases de clôture réglementaire Solvabilité 2, où la finesse de l'analyse des risques doit impérativement se concilier avec la performance d'exécution pour permettre le lancement de multiples sensibilités et scénarios économiques.

L'enjeu sous-jacent consiste à relever un défi majeur d'optimisation : réduire drastiquement la volumétrie des données en entrée du modèle ALM tout en garantissant la stricte fidélité des indicateurs prudentiels (BE et SCR). Pour y parvenir, l'objectif de ce chapitre est d'exposer de manière exhaustive les fondements algorithmiques des différentes approches d'agrégation qui seront comparées dans ce mémoire, à travers l'étude de trois grandes familles de méthodes :

— **Les approches déterministes classiques :** Méthodes traditionnellement utilisées sur le marché, elles reposent sur une segmentation experte du portefeuille par caractéristiques communes ou par tranches (*Banding*). Elles serviront de référence pour évaluer l'apport des techniques plus complexes.

— **Les approches statistiques par apprentissage non supervisé :** L'apport des algorithmes de *Machine Learning*, tels que les algorithmes de partitionnement (K-Means), basés sur la densité (DBSCAN, HDBSCAN) ou les arbres de décision (CART), sera exploré pour constituer des *Model Points* fondés sur une similarité multidimensionnelle des profils de risque.

— **Les approches dynamiques basées sur les flux financiers :** En rupture avec le regroupement spatial statique, ces méthodes avancées (telles que le *Cash-Flow Matching* et l'approche par calibration *a posteriori*) proposent d'agréger les contrats en fonction de leur comportement projeté et de leur cinétique d'écoulement.

L'exposé détaillé de ces modèles nous permettra de poser le socle théorique nécessaire avant d'aborder, dans le chapitre suivant, le protocole de test standardisé et l'analyse comparative de leurs performances respectives.

3.1 Les approches déterministes : Le standard de marché

Avant d'explorer les algorithmes statistiques avancés, il est indispensable de définir la méthode de référence classiquement utilisée par les directions actuarielles. Les approches déterministes ne s'appuient pas sur une recherche algorithmique de similarités spatiales, mais sur l'application stricte de règles métier pour segmenter le portefeuille. L'objectif de cette première section est de présenter cette méthode historique, qui fera office de base de comparaison pour évaluer objectivement les performances des techniques d'agrégation présentées dans la suite de ce chapitre.

3.1.1 Segmentation stricte par regroupement de caractéristiques

La méthode par regroupement de caractéristiques repose sur une segmentation par classes de risque, cette approche constitue le standard historique en actuariat. Elle servira de base de comparaison pour évaluer la performance des algorithmes de regroupement statistique plus avancés présentés dans les parties suivantes.

Le principe fondamental repose sur une partition déterministe du portefeuille. L'objectif est de regrouper les contrats partageant des caractéristiques de risque identiques. Dans un modèle de projection de gestion actif-passif, l'évolution de la PM est influencée par des caractéristiques spécifiques du contrat. La mortalité dépend de la génération, de l'âge et du sexe ; les rachats sont corrélés à l'âge de l'assuré et à l'ancienneté du contrat ; la revalorisation dépend du TMG.

Par conséquent, pour garantir que le Model Point agrégé se comporte comme la somme des contrats individuels, il est impératif de regrouper les polices selon ces axes discriminants. Contrairement aux méthodes statistiques qui cherchent des similarités globales, cette approche applique une segmentation rigide. Les critères de regroupement retenus pour cette étude sont :

— **Le sexe** : Indispensable pour l'application des tables de mortalité différenciées.

— **Le TMG** : Crucial pour la valorisation des garanties financières.

— **L'âge de l'assuré** : Discrétisé à l'entier inférieur pour correspondre aux entrées des tables de mortalité.

— **L'ancienneté du contrat** : Discrétisée à l'entier inférieur pour modéliser correctement la fiscalité et les rachats structurels.

Mathématiquement, cette méthode définit une relation d'équivalence stricte. Deux contrats i et j appartiennent au même Model Point k si et seulement si leurs vecteurs de caractéristiques discrétisées sont identiques :

$$(S_i, \lfloor A_i \rfloor, \lfloor Anc_i \rfloor, TMG_i) = (S_j, \lfloor A_j \rfloor, \lfloor Anc_j \rfloor, TMG_j) \tag{3.1}$$

Où S_i, A_i et Anc_i désignent respectivement le sexe, l'âge et l'ancienneté du contrat i. Une fois les groupes constitués, l'agrégation s'opère par la somme des variables extensives. La provision mathématique du Model Point k (associé à la classe d'équivalence C_k) est alors la somme des encours des contrats qui le constituent :

$$PM_{MP_k} = \sum_{i \in C_k} PM_i \tag{3.2}$$

Les variables intensives du Model Point (dont la valeur est indépendante de la taille du groupe, comme l'âge ou l'ancienneté) prennent alors les valeurs définies par la segmentation (par exemple, 45 ans et 10 ans), et non une moyenne pondérée, ce qui est cohérent avec la logique de discrétisation à l'entier.

Cette approche présente l'avantage majeur de la simplicité et de la transparence. Elle conserve exactement la volumétrie financière du portefeuille et respecte scrupuleusement les garanties contractuelles (absence de dilution du TMG par moyenne). Elle garantit une homogénéité parfaite des assurés au sein d'un groupe.

Cependant, elle présente des limites intrinsèques :

— **La rigidité de la structure de regroupement :** La définition des classes est fixée *a priori* et de manière uniforme, sans tenir compte de la distribution réelle des capitaux. Cette approche ne permet pas de concentrer automatiquement la précision du regroupement sur les zones à fort enjeux financiers, traitant potentiellement avec la même granularité les segments marginaux et les segments prépondérants.

— **L'absence de contrôle sur la compression :** Le nombre de *Model Points* finaux n'est pas paramétrable. Il dépend exclusivement de la dispersion du portefeuille et de la finesse de la segmentation. Sur un portefeuille très hétérogène, cette méthode peut générer un nombre de groupes très élevé, dont certains ne contiendront que peu de contrats, limitant ainsi l'efficacité de la réduction de dimension (phénomène du fléau de la dimension).

3.1.2 Approche par tranches (Banding) et pondération financière

Cette méthode constitue une évolution de la segmentation par classes présentée précédemment. Elle vise à réduire davantage le nombre de Model Points en relâchant la contrainte d'égalité stricte sur les variables continues (âge et ancienneté) au profit d'une logique d'intervalles, ou discrétisation par paliers.

Le principe de regroupement reste déterministe. Les variables catégorielles ou contractuelles majeures (Sexe, TMG) conservent une discrimination stricte. En revanche, l'espace des variables temporelles est découpé en tranches. Dans le cadre de cette implémentation, les intervalles suivant ont été retenus :

— Un pas de 2 ans pour l'âge de l'assuré ;

— Un pas de 5 ans pour l'ancienneté du contrat.

Un contrat i appartient à un groupe k si ses caractéristiques discrètes correspondent et si ses variables continues tombent dans les intervalles définis :

$$i \in C_k \iff \begin{cases} S_i = S_k \\ TMG_i = TMG_k \\ A_i \in [A^k_{min}, A^k_{max}[\\ Anc_i \in [Anc^k_{min}, Anc^k_{max}[\end{cases} \tag{3.3}$$

La spécificité majeure de cette approche réside dans la détermination des caractéristiques du Model Point. Contrairement à une approche simpliste qui retiendrait le centre de l'intervalle, il convient de calculer le barycentre financier des contrats regroupés. Ainsi, l'âge (A_{MP_k}) et l'ancienneté (Anc_{MP_k}) du Model Point k sont calculés comme suit :

$$A_{MP_k} = \frac{\sum_{i \in C_k} A_i \cdot PM_i}{\sum_{i \in C_k} PM_i} \quad ; \quad Anc_{MP_k} = \frac{\sum_{i \in C_k} Anc_i \cdot PM_i}{\sum_{i \in C_k} PM_i} \tag{3.4}$$

Cette pondération par les encours permet de s'assurer que le Model Point est représentatif des contrats les plus significatifs financièrement au sein de la tranche, minimisant ainsi le biais d'agrégation sur les projections de flux futurs.

3.1.2.1 Variante Smart Granular et limites (Biais d'agrégation et variance intra-classe)

Dans le cadre de l'optimisation, une variante nommée **Smart Granular** a été développée. Contrairement au Banding classique à pas constant, cette approche adapte la finesse des mailles selon la sensibilité locale des risques. Plusieurs profils de découpage ont été implémentés pour répondre à des objectifs d'analyse différents :

— **Smart Focus Active :** Priorise la précision sur la phase de constitution de l'épargne (20-65 ans) avec un pas de 2 ans, tout en compressant fortement les extrêmes (pas de 15 ans au-delà de 85 ans).

— **Smart Focus Young :** Stratégie ultra-fine sur les nouveaux entrants (pas de 1 an jusqu'à 50 ans) pour capturer la dynamique de croissance du portefeuille.

— **Smart Focus Fiscal :** Découpage spécifique autour de l'ancienneté 8 ans (pas de 1 an entre 0 et 12 ans) pour modéliser avec précision le basculement de la fiscalité des rachats.

— **Smart Granular (Équilibré) :** Mélange des approches précédentes, resserrant les mailles à la fois sur l'âge et sur le cap fiscal des 8 ans.

3.1.2.2 Limites de l'approche et variance intra-classe

Bien que la pondération par la provision mathématique assure la conservation du barycentre financier, le regroupement par tranches (Banding) écrase inévitablement la dispersion au sein de chaque groupe. Mathématiquement, la variance intra-classe (ou inertie) d'une tranche k pour une caractéristique X (comme l'âge) s'exprime par :

$$Var(X_k) = \frac{1}{\sum_{i \in MP_k} PM_i} \sum_{i \in MP_k} PM_i (X_i - X_{MP_k})^2 \tag{3.5}$$

Plus la tranche est large, plus cette variance augmente, ce qui dilue la précision du profil de risque. Le modèle ALM traitant les flux de manière non linéaire (notamment via les probabilités de rachat ou de mortalité), cette perte de dispersion engendre le fameux biais d'agrégation. C'est cette limitation fondamentale qui justifie le recours à des algorithmes de partitionnement dynamique. Plutôt que de subir une grille d'agrégation statique et arbitraire qui contraint la donnée, il apparaît nécessaire d'adopter des approches où la structure intrinsèque du portefeuille dicte elle-même la formation des groupes. Les méthodes d'apprentissage non supervisé, explorées dans la section suivante, répondent précisément à cet impératif en cherchant à minimiser l'inertie intra-classe de manière algorithmique.

3.2 Les approches statistiques spatiales (Apprentissage non supervisé)

Cette famille de méthodes repose sur les techniques d'apprentissage non supervisé, et plus particulièrement sur les algorithmes de *clustering*. L'idée centrale est de représenter chaque contrat d'assurance comme un point dans un espace géométrique multidimensionnel, où chaque dimension correspond à une caractéristique financière ou biométrique du passif (âge, ancienneté, PM, TMG, etc.). L'objectif de cette section est de détailler comment ces algorithmes exploitent la notion de distance spatiale pour regrouper les profils similaires en *Model Points*.

Toutefois, avant même d'aborder la mécanique interne des algorithmes de partitionnement, une étape préliminaire s'avère indispensable pour garantir la pertinence mathématique des distances calculées.

3.2.1 Préparation de l'espace spatial : techniques transverses

Au-delà du choix de l'algorithme de clustering, la performance de l'agrégation dépend fortement de la préparation des données et des contraintes métier imposées lors du processus.

Stratification par risques majeurs (TMG et Sexe)

Afin d'éviter des compensations de risques biologiquement ou financièrement absurdes, une stratégie a été systématiquement appliquée avant l'agrégation. Le portefeuille est d'abord divisé en strates étanches selon :

— **Le sexe :** Pour garantir le respect des tables de mortalité différenciées.

— **Le TMG :** Pour éviter de diluer la valeur des garanties financières.

L'algorithme de clustering (K-Means ou HDBSCAN) est ensuite lancé indépendamment au sein de chaque strate. Cette approche garantit une pureté minimale des Model Points finaux.

Ingénierie des caractéristiques : Log-PM et poids dimensionnels

Pour orienter les algorithmes vers les zones à fort enjeux, deux techniques de *Feature Engineering* ont été testées :

— **Ajout de la dimension Log-PM :** Le logarithme de la Provision Mathématique est ajouté comme variable spatiale. Cela force l'algorithme à regrouper des contrats de taille financière similaire, évitant qu'un gros contrat ne soit noyé dans une masse de petits contrats.

— **Pondération des dimensions :** Lors du calcul de la distance euclidienne, des poids w_d sont appliqués. Par exemple, une importance de 10 est donnée au TMG contre 1 pour l'Âge, pour s'assurer que la proximité financière prime sur la proximité démographique.

3.2.2 Partitionnement par inertie : k-moyennes (K-Means) pondéré

Contrairement aux méthodes déterministes qui segmentent l'espace des risques selon une grille préétablie, les approches par apprentissage non supervisé (Machine Learning) visent à déterminer la structure des données. L'objectif n'est plus d'imposer un regroupement, mais de laisser l'algorithme identifier les zones de forte densité du portefeuille pour y placer les groupes semblables, dans notre cas les Model Points.

Parmi les algorithmes de clustering, la méthode des K-Means a été retenue car c'est une méthode robuste et fonctionne très bien pour minimiser l'inertie intra-classe, c'est-à-dire la dispersion des contrats autour de leur Model Point représentatif.

3.2.2.1 Principe de l'algorithme

L'algorithme des K-Means cherche à partitionner un ensemble de N contrats en K groupes (ou clusters) distincts, de manière à minimiser la distance entre chaque contrat et le centre de son groupe (le centroïde). Dans notre contexte, ce centroïde deviendra le Model Point.

Mathématiquement, pour un ensemble de contrats représentés par des vecteurs de caractéristiques $x_i \in \mathbb{R}^d$ (où d est le nombre de dimensions : âge, ancienneté, TMG...), l'algorithme cherche à déterminer les K centroïdes $\mu_1, ..., \mu_K$ qui minimisent la fonction objectif J (l'inertie) :

$$J = \sum_{j=1}^{K} \sum_{x_i \in C_j} w_i \left\| x_i - \mu_j \right\|^2 \tag{3.6}$$

Où :

- C_j est l'ensemble des contrats assignés au cluster j.
- $||.||$ est la distance/norme utilisée (ici norme euclidienne).
- w_i est le poids du contrat i, ici cela correspond à la provision mathématique (PM_i). Ainsi, l'algorithme est forcé de minimiser l'erreur de regroupement prioritairement pour les contrats à fort enjeux financiers.

3.2.2.2 Application aux données du portefeuille

La mise en œuvre de cet algorithme sur un portefeuille d'épargne nécessite plusieurs étapes pour garantir la pertinence des regroupements : le choix des variables, la standardisation des données, et l'adaptation de l'algorithme pour intégrer la pondération par la PM.

Les variables retenues pour le calcul de la distance sont celles qui impactent directement le profil de risque et les flux futurs :

- **L'âge de l'assuré** ;
- **L'ancienneté fiscale** ;

— **Le TMG**.

Ces variables ayant des échelles très différentes (un âge varie de 0 à 100, un TMG de 0 à 0.04), un calcul de distance brut donnerait un poids disproportionné à l'âge. Il est donc impératif de procéder à une standardisation (centrage-réduction) des données avant le clustering :

$$\tilde{x}_{i,d} = \frac{x_{i,d} - \mu_d}{\sigma_d} \tag{3.7}$$

Cette transformation place toutes les variables sur une échelle comparable, permettant à l'algorithme de traiter équitablement les différentes dimensions du risque.

L'algorithme utilisé est une variante pondérée des K-Means. Contrairement à une approche standard où chaque point a une importance égale, ici chaque contrat attire le centroïde proportionnellement à sa PM. Le processus itératif est le suivant :

1. **Initialisation :** Sélection des K centroïdes initiaux via la méthode **k-means**++. Contrairement à une initialisation totalement aléatoire qui risque de conduire à des optimums locaux de mauvaise qualité, cet algorithme répartit les centres initiaux de manière espacée. Le premier centroïde est choisi au hasard, puis chaque centroïde suivant est sélectionné avec une probabilité proportionnelle au carré de la distance qui le sépare du centroïde le plus proche déjà choisi ($D(x)^2$). Cela accélère considérablement la convergence.
2. **Affectation :** Chaque contrat est assigné au centroïde le plus proche en termes de distance euclidienne pondérée.
3. **Mise à jour :** Les nouveaux centroïdes sont recalculés comme le barycentre pondéré des contrats de leur cluster.
4. **Convergence :** Répétition des étapes 2 et 3 jusqu'à stabilisation des centroïdes.

3.2.2.3 Constitution des Model Points finaux

Une fois la convergence atteinte, chaque cluster j est transformé en un Model Point unique.

— Les variables extensives (PM, nombre de contrats) sont sommées : $PM_{MP_j} = \sum_{i \in S_j} PM_i$.

— Les variables intensives (âge, ancienneté, TMG) sont définies par les coordonnées du centroïde final, qui correspondent naturellement à la moyenne pondérée des caractéristiques des contrats du cluster.

Cette méthode permet de définir automatiquement des Model Points situés au cœur des masses financières du portefeuille, comme illustré dans la Figure 3.1, offrant ainsi une représentation optimale de la distribution des risques.

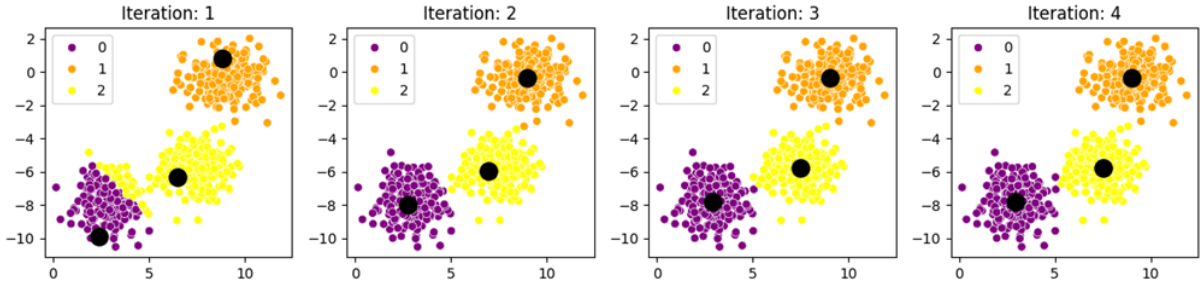

FIGURE 3.1 – Visualisation de la méthode K-Means sur un jeu de données fictif [11]

Bien que l'algorithme des K-Means s'avère performant pour minimiser la variance au sein des groupes, il repose sur une hypothèse géométrique forte : il tend à construire des partitions sphériques (ou convexes) de tailles comparables. Or, la réalité d'un portefeuille d'assurance vie se caractérise souvent par des densités très hétérogènes et des formes irrégulières. Par exemple, la commercialisation massive d'une génération spécifique de produits sur une courte période crée une concentration locale de polices dont la forme dans l'espace des données est non convexe. Expliquer le terme convexe à un moment du mémoire

Pour capter ces niches complexes sans forcer l'homogénéité des volumes ni fixer *a priori* le nombre de *Model Points*, il convient de s'affranchir de la notion de distance pure au profit d'une analyse de la concentration locale des données.

C'est pour répondre à ce besoin que des méthodes basées sur la densité peuvent être mises en place, à l'image de l'algorithme DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) et de son extension hiérarchique HDBSCAN.

3.2.3 Partitionnement par densité : DBSCAN (introduction du Dithering et gestion du bruit par k-NN)

3.2.3.1 Principes fondamentaux de DBSCAN

L'algorithme DBSCAN définit un cluster comme une zone de forte densité séparée par des zones de faible densité. Il repose sur deux paramètres clés : un rayon de voisinage ε (*epsilon*) et un nombre minimum de points $MinPts$.

Mathématiquement, la notion de densité est formalisée par le voisinage ε d'un point x, noté $N_\varepsilon(x)$: $N_\varepsilon(x) = \{y \in D \mid d(x, y) \leq \varepsilon\}$

Un point x est qualifié de **point cœur** (*core point*) si son voisinage contient au moins $MinPts$ points : $|N_\varepsilon(x)| \geq MinPts$.

À partir de cette définition, les clusters sont construits par propagation de la propriété de *densité-accessibilité* :

— Un point p est directement densité-accessible depuis q si q est un point cœur et $p \in N_\varepsilon(q)$.

— Un cluster est alors l'ensemble maximal de points connectés par cette relation de densité.

— Tout point n'appartenant à aucun cluster est considéré comme du **bruit** (*outlier*).

FIGURE 3.2 – Explication de l'algorithme DBSCAN (TODO : A refaire)

3.2.3.2 Adaptation aux contraintes assurantielles

L'application directe de DBSCAN aux données brutes du portefeuille d'assurance vie utilisé se heurte à deux obstacles majeurs nécessitant des adaptations spécifiques implémentées dans le protocole : Le problème de la discrétisation et la gestion du bruit.

Les variables de gestion (âge, ancienneté) sont traditionnellement stockées de manière discrète. Cette structure crée une grille artificielle où plusieurs contrats se superposent exactement sur les mêmes coordonnées (x, y). Cela fausse le calcul de densité locale : un point isolé sur la grille peut artificiellement paraître très dense simplement parce qu'il superpose plusieurs contrats identiques au mêmes caractéristiques.

Pour y remédier, une technique de **Dithering** (bruitage uniforme) peut être utilisée. Avant l'étape de clustering, une perturbation aléatoire u_i est ajoutée aux variables temporelles de chaque contrat x_i :

$\tilde{x}_{i,d} = x_{i,d} + u_{i,d} \quad \text{avec} \quad u_{i,d} \sim \mathcal{U}([-0.5, 0.5])$

Cette transformation permet alors de fluidifier l'espace et d'éviter une trop grande densité des contrats, sans altérer les propriétés statistiques globales du portefeuille (l'espérance de la perturbation étant nulle).

3.2.3.3 Gestion du bruit et réallocation des contrats

Contrairement à une analyse de données classique exploratoire où le bruit peut être écarté, dans un modèle épargne, la complétude des engagements est une contrainte absolue :

$\sum PM_{MP} = \sum PM_{contrats}$.

Les contrats classés comme « bruit » par DBSCAN (zones de faible densité ou points isolés) ne peuvent être ignorés.

Il a donc fallu implémenter une étape de post-traitement systématique : une réallocation via un algorithme des **k-plus proches voisins (k-NN)** avec $k = 1$. Chaque contrat identifié comme bruit x_{noise} est réaffecté au cluster validé C_j le plus proche : $Class(x_{noise}) = Class(\underset{y \in \text{Clustered}}{\text{argmin}} \; d(x_{noise}, y))$ Cela garantit qu'aucun contrat n'est perdu tout en rattachant les profils atypiques aux segments les plus ressemblants.

FIGURE 3.3 – Explication du reclassement du bruit (TODO : A refaire)

3.2.4 L'extension hiérarchique adaptative : HDBSCAN (distance d'accessibilité, extraction EOM vs Leaf)

Bien que l'algorithme DBSCAN permette de créer des clusters sur des données non sphériques comme le fait l'algorithme K-Means, il conserve une limite majeure : l'utilisation d'un seuil de densité global (ε)

unique. Dans un portefeuille d'assurance vie, la densité des données est hétérogène. Certaines zones, correspondant aux produits récemment commercialisés, présentent une très forte concentration de contrats, tandis que d'autres, regroupant des générations anciennes ou des produits de niche, sont beaucoup plus diffuses. L'application d'un ε unique conduit inévitablement à un compromis insatisfaisant : un seuil strict fragmente les zones diffuses en bruit, tandis qu'un seuil lâche fusionne des clusters distincts dans les zones denses.

Pour répondre à cette problématique, l'algorithme **HDBSCAN** (*Hierarchical Density-Based Spatial Clustering of Applications with Noise*) propose une approche hiérarchique permettant de détecter des clusters de densités variables. Son fonctionnement se décompose en cinq étapes séquentielles majeures [13] :

1. La transformation de l'espace métrique (pour isoler le bruit) ;
2. La construction d'un graphe (arbre couvrant minimum) ;
3. La formation de la hiérarchie des clusters ;
4. La condensation de l'arbre hiérarchique ;
5. L'extraction dynamique des clusters finaux.

Les sous-parties suivantes détaillent la mécanique mathématique de chacune de ces étapes.

3.2.4.1 Étape 1 : Transformation de l'espace (la distance d'accessibilité mutuelle)

Afin de rendre l'algorithme plus robuste aux points aberrants (bruit), HDBSCAN ne travaille pas directement sur la distance euclidienne brute, mais définit une nouvelle métrique : la distance d'accessibilité mutuelle.

3.2.4.2 Transformation de l'espace : la distance d'accessibilité mutuelle

Afin de rendre l'algorithme plus robuste aux points aberrants (bruit), HDBSCAN ne travaille pas directement sur la distance euclidienne brute, mais définit une nouvelle métrique : la distance d'accessibilité mutuelle.

$$d_{mreach}(a, b) = \max\{\text{core}_k(a), \text{core}_k(b), d(a, b)\} \tag{3.8}$$

Où $\text{core}_k(x)$ est la distance du point x à son k-ième voisin le plus proche. Cette métrique permet de pondérer la distance entre deux points par leur densité locale : si un point se trouve dans une zone de faible densité, sa distance de cœur sera élevée, augmentant ainsi sa distance mutuelle d_{mreach} avec les autres points. Cette transformation a pour effet d'isoler les points aberrants en les repoussant hors des zones de forte concentration, ce qui stabilise la formation des clusters.

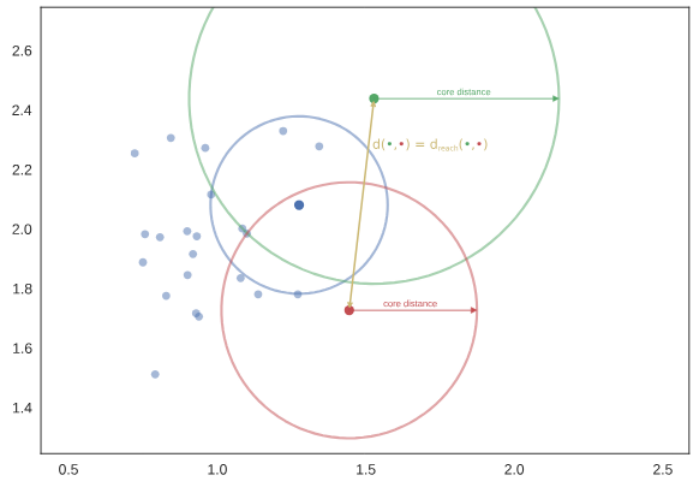

FIGURE 3.4 – Illustration de la distance d'accessibilité mutuelle [13] citer tous les graphes de la section dans le texte pour relier l'explication

Ayant établi une mesure de distance robuste aux valeurs aberrantes, l'algorithme procède ensuite à la structuration topologique des données.

3.2.4.3 Construction de l'arbre couvrant minimum (MST)

L'algorithme construit ensuite un graphe où chaque contrat est un sommet, relié aux autres par des arêtes pondérées par la distance d_{mreach}. Un arbre couvrant minimum (*Minimum Spanning Tree* - MST) est généré pour connecter l'ensemble des points en minimisant le poids total des arêtes.

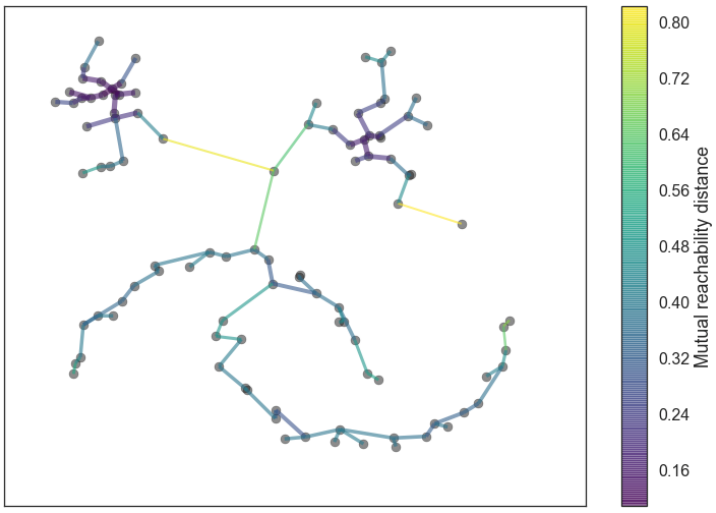

FIGURE 3.5 – Construction de l'Arbre Couvrant Minimum [13]

3.2.4.4 Construction de la hiérarchie des clusters

En supprimant itérativement les arêtes du MST par ordre décroissant de poids, l'algorithme déconnecte progressivement le graphe. Cela crée une structure dendrogrammatique (arbre hiérarchique) représentant l'ensemble des regroupements possibles, du plus global (un seul cluster) au plus fin (chaque point est un cluster).

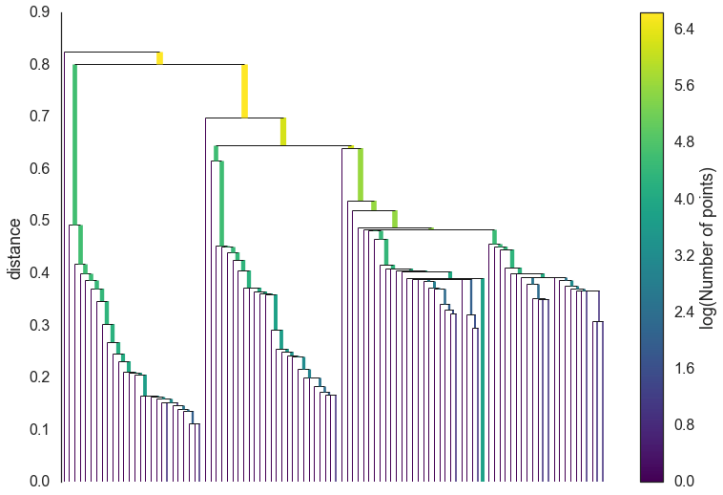

FIGURE 3.6 – Construction de la hiérarchie des clusters [13]

3.2.4.5 Condensation de l'arbre

L'arbre hiérarchique complet étant trop complexe, il est condensé. À chaque séparation, la taille minimale des nouveaux groupes formés est vérifiée si les nouveaux groupes formés atteignent une taille minimale ($MinPts$). Si ce n'est pas le cas, les points sont considérés comme du bruit détaché du cluster principal. Si les deux branches sont suffisamment grandes, il est considéré qu'il y a naissance de deux vrais clusters. Cette étape simplifie drastiquement l'arbre en ne conservant que les branches significatives.

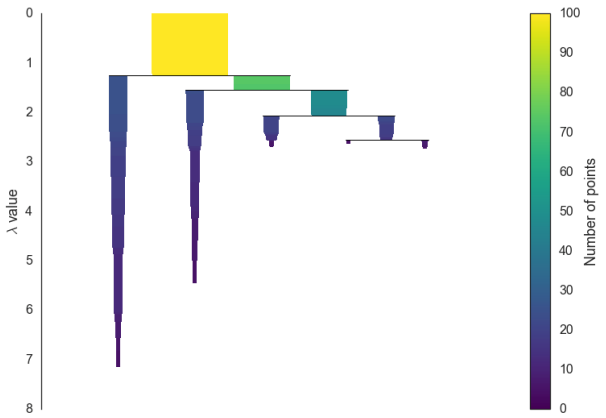

FIGURE 3.7 – Condensation de l'arbre hiérarchique [13]

3.2.4.6 Extraction des clusters stables

Contrairement aux méthodes hiérarchiques classiques qui coupent l'arbre à un niveau fixe, HDBSCAN sélectionne les clusters en maximisant une mesure de stabilité appelée *Excess of Mass* (eom). La stabilité d'un cluster est définie par la somme, pour tous ses points, de la différence entre la densité à laquelle le point quitte le cluster (λ_{death}) et celle où le cluster est apparu (λ_{birth}) :

$$\mathcal{S}(C) = \sum_{x \in C} (\lambda_{death}(x) - \lambda_{birth}(C)) \tag{3.9}$$

L'algorithme remonte l'arbre condensé et sélectionne l'ensemble de clusters disjoints qui maximise cette stabilité globale.

3.2.4.7 Stratégies d'extraction des clusters : EOM vs Leaf

Deux stratégies de sélection des nœuds dans la hiérarchie ont été mises en concurrence :

— **EOM (Excess of Mass) :** C'est la méthode par défaut de l'algorithme, elle sélectionne les clusters présentant la plus grande stabilité en surface dans l'arbre hiérarchique. Cette méthodologie permet d'identifier simultanément des micro-clusters très compacts et des macro-clusters plus étendus, offrant une segmentation optimale et adaptative de la population des assurés sans paramétrage complexe d'un rayon de voisinage.

— **Leaf (Feuilles) :** Cette variante force l'algorithme à sélectionner uniquement les nœuds terminaux de l'arbre condensé (les feuilles). Elle garantit l'homogénéité maximale au sein de chaque Model Point en évitant toute fusion, au prix d'un nombre de MP plus important.

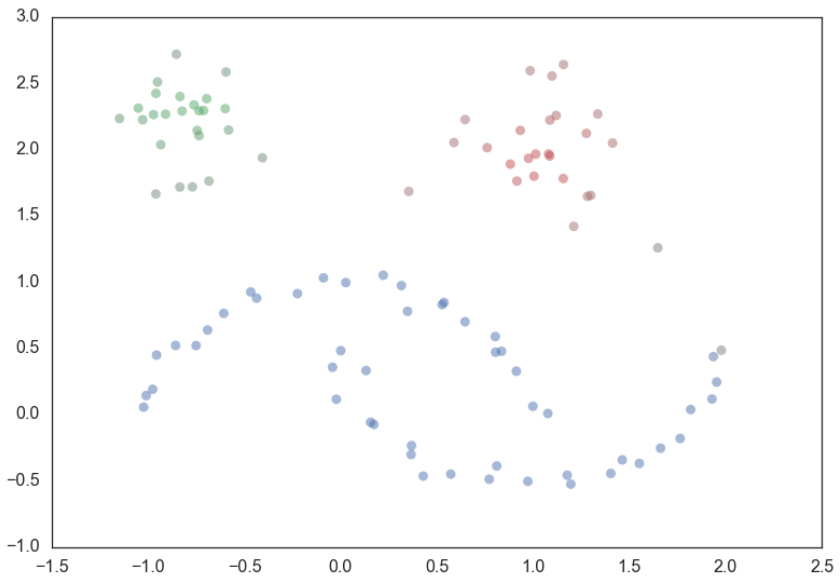

FIGURE 3.8 – Résultat final du clustering HDBSCAN [13] citer les graphes et expliquer

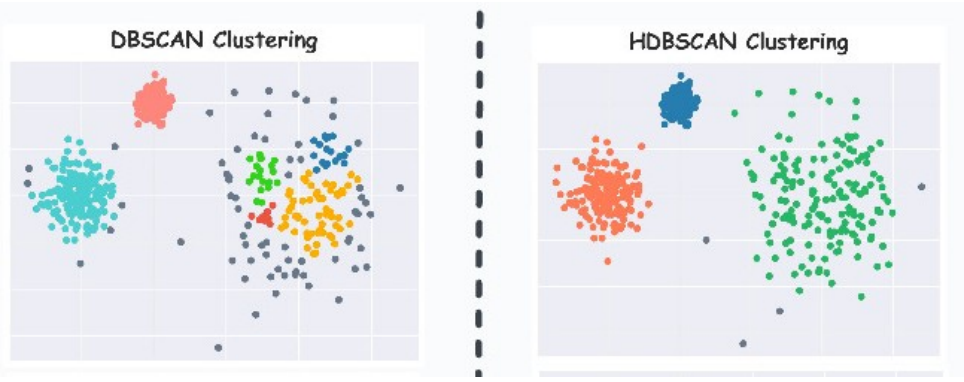

FIGURE 3.9 – Comparaison des approches DBSCAN et HDBSCAN [12] citer les graphes et expliquer

3.2.4.8 Constitution finale des Model Points

Une fois la partition optimale obtenue (via DBSCAN ou HDBSCAN) et le bruit réalloué, la construction des Model Points suit la logique de conservation des flux financiers. Pour chaque cluster j, le Model Point est défini par le barycentre pondéré des contrats :

$$\mu_j = \frac{\sum_{i \in C_j} PM_i \cdot x_i}{\sum_{i \in C_j} PM_i}$$

Cette méthode assure que le Model Point se situe au centre de gravité financier de son groupe, minimisant ainsi le biais d'agrégation sur les projections futures.

refaire les modélisations en utilisant un peu toutes les méthodes

Bien que les algorithmes de *clustering* spatial offrent des solutions robustes pour regrouper les contrats selon leurs similarités géométriques, ils opèrent de manière non supervisée. Ils structurent l'espace des données sans tenir compte de l'impact financier réel de ces regroupements sur le modèle ALM. Pour pallier cette limite et orienter la construction des *Model Points* autour d'un enjeu actuariel précis, il convient d'explorer une seconde grande famille d'algorithmes : les méthodes supervisées. Celles-ci utilisent une variable cible (telle que la provision mathématique ou un flux de trésorerie) pour guider mathématiquement la partition du portefeuille.

3.3 L'approche par segmentation supervisée

Alors que les méthodes d'apprentissage non supervisé (K-Means, HDBSCAN) cherchent à regrouper les contrats selon une similarité globale de leurs caractéristiques, elles ne garantissent pas structurellement l'homogénéité d'un indicateur financier précis. Pour pallier cette limite et forcer la modélisation à se concentrer sur les enjeux de rentabilité (comme le TMG), il convient de se tourner vers des algorithmes d'apprentissage supervisé.

3.3.1 Principe des arbres de décision (CART) appliqués au passif

L'approche par arbres de décision, et plus précisément l'algorithme CART (*Classification and Regression Trees*), introduit une logique d'apprentissage supervisé dans le processus d'agrégation. Contrairement aux approches non supervisées qui évaluent une similarité spatiale globale, le modèle CART partitionne l'espace des caractéristiques en cherchant à expliquer au mieux la variance d'une variable cible continue. Il s'agit ici d'un arbre de régression.

3.3.1.1 Formalisation mathématique du critère de partitionnement

L'algorithme procède par séparations binaires successives de l'espace des caractéristiques du contrat : {âge, ancienneté, TMG}. À chaque nœud m de l'arbre, représentant un sous-ensemble N_m de contrats, l'objectif est de trouver la variable de coupe j et le seuil s qui minimisent l'impureté des deux nœuds enfants formés (gauche et droit).

Afin de respecter la volumétrie financière du portefeuille, le critère d'impureté $H(m)$ retenu est la variance pondérée par la provision mathématique ($w_i = PM_i$). Pour une variable cible Y_i, l'impureté du nœud m s'exprime ainsi :

$$H(m) = \frac{1}{\sum_{i \in N_m} w_i} \sum_{i \in N_m} w_i (Y_i - \bar{Y}_m)^2 \tag{3.10}$$

Où $\bar{Y}_m$ est la moyenne pondérée de la cible au sein du nœud :

$$\bar{Y}_m = \frac{\sum_{i \in N_m} w_i Y_i}{\sum_{i \in N_m} w_i} \tag{3.11}$$

Pour chaque itération, l'algorithme sélectionne le couple (j, s) qui minimise la fonction de coût $G(j, s)$, correspondant à la somme des impuretés pondérées des nœuds enfants :

$$G(j, s) = \frac{W_{gauche}}{W_m} H(m_{gauche}) + \frac{W_{droit}}{W_m} H(m_{droit}) \tag{3.12}$$

Où W représente la somme des poids (PM) des contrats dans le nœud considéré. Le processus s'arrête lorsqu'un nombre maximal de feuilles (correspondant au nombre de Model Points souhaité) est atteint.

3.3.2 Définition des variables cibles (refined vs spread focus)

La puissance de l'arbre CART réside dans le choix de la métrique à optimiser :

— **Variante refined (Risque mixte) :** Une variable cible d'intérêt Y_i est définie par $Y_i = PM_i \times (1 + \alpha \cdot TMG_i)$, avec $\alpha = 10$ défini empiriquement. Cette pondération force l'arbre à accorder plus d'importance aux contrats qui pèsent lourd financièrement tout en ayant un coût de garantie élevé. C'est une approche visant l'équilibre entre masse et risque.

— **Variante spread focus (Pureté financière) :** La cible est le TMG pur, défini ici par $Y_i = TMG_i$. Pondéré par la PM, l'algorithme cherche alors à créer des groupes où l'hétérogénéité des taux garantis est minimale. Cette approche est privilégiée pour les modèles ALM très sensibles au spread entre taux de marché et taux techniques, car elle isole parfaitement les poches de garanties coûteuses.

Cette méthode présente l'avantage d'identifier automatiquement les interactions non linéaires entre les variables (par exemple, un seuil d'âge qui ne devient critique que pour une certaine ancienneté). Cependant, elle produit une segmentation par paliers qui peut s'avérer trop brutale pour modéliser des phénomènes continus comme la mortalité.

Toutes les méthodes de partitionnement spatial abordées jusqu'ici, qu'elles soient supervisées ou non, partagent une limite conceptuelle commune : elles évaluent la similarité des profils de risque de manière purement statique, à la date d'arrêté. Pour franchir un nouveau cap de fidélité financière, une rupture méthodologique s'impose : agréger les contrats non plus sur ce qu'ils sont, mais sur ce qu'ils vont produire.

3.4 Les approches dynamiques basées sur l'écoulement des flux

3.4.1 Appariement comportemental (Cash-Flow Matching) et niveaux de fidélité (Proxy vs Real OPS)

La méthode de *Cash-Flow Matching* constitue l'approche la plus avancée de ce protocole. Elle repose sur un changement de paradigme : les contrats sont regroupés selon leur **profil de risque dynamique**.

Le principe s'articule en deux phases :

1. **Phase de projection proxy :** Chaque contrat individuel i est projeté au sein du modèle ALM en mode passif seul sous un scénario déterministe central sur un horizon de $T = 20$ ans. Un vecteur de flux financiers est extrait de cette projection $\mathbf{CF}_i = [f_{i,1}, f_{i,2}, ..., f_{i,T}]$, où $f_{i,t}$ représente la somme des prestations (rachats, décès, termes) et de la marge financière à l'année t.
2. **Phase de clustering :** L'algorithme des K-Means est ensuite appliqué non pas sur les données de gestion, mais sur ces vecteurs de flux $\mathbf{CF}_i$. La distance entre deux contrats est alors définie par leur proximité comportementale dans le temps :

$$d(i,j) = \sqrt{\sum_{t=1}^{T} w_t (f_{i,t} - f_{j,t})^2} \tag{3.13}$$

3.4.1.1 Niveaux de fidélité du moteur proxy

Cette approche a été déclinée en deux versions selon la complexité du moteur de projection utilisé pour générer les vecteurs $\mathbf{CF}_i$:

— **Mode proxy (simple) :** Utilise un modèle simplifié, souvent linéaire ou déterministe de premier ordre, pour projeter les flux. C'est une méthode rapide mais qui peut négliger les effets de second ordre comme l'épuisement de la PPE.

— **Mode Real OPS (moteur métier) :** Utilise le véritable moteur de calcul Polars développé pour ce mémoire. Bien que plus coûteux en temps de préparation (env. 30s), il garantit que le clustering s'opère sur la réalité économique exacte du contrat, capturant l'intégralité des non-linéarités (participation aux bénéfices, rachats structurels, fiscalité).

Cette approche, désignée sous le terme **Real OPS** dans cette étude, permet de capturer intrinsèquement toutes les non-linéarités du modèle ALM. Deux contrats présentant des caractéristiques très différentes (par exemple, un assuré jeune sur un contrat ancien et un assuré âgé sur un contrat récent) peuvent être regroupés s'ils génèrent des flux de sortie statistiquement équivalents.

L'avantage majeur est la réduction drastique du biais d'agrégation puisque le critère de regroupement est précisément l'indicateur calculé *in fine* (le Best Estimate). L'inconvénient réside dans le coût computationnel de la pré-projection initiale, qui doit être compensé par le gain de temps lors des lancements

ALM ultérieurs.

3.4.2 Calibration de lois *a posteriori* (Méthode *Biais Zéro* et clés financières)

L'approche par calibration *a posteriori*, dénommée *Biais Zéro* dans cette étude, marque une rupture méthodologique fondamentale avec les techniques de *clustering* traditionnelles. Le paradigme est ici inversé : au lieu de chercher à regrouper des polices démographiquement similaires pour leur appliquer des lois de comportement standards, cette méthode s'autorise à regrouper les contrats selon des critères purement financiers. Elle recalcule ensuite mathématiquement des probabilités de sortie « sur-mesure » (taux de rachat et de mortalité induits) pour chaque groupe.

Cette méthode modifie la notion même de *Model Point*. Contrairement aux approches déterministes ou spatiales, un *Model Point* issu de cette calibration ne possède plus d'âge moyen, de sexe majoritaire ou d'ancienneté. Il se résume à une pure enveloppe de flux financiers, rattachée à une table de sortie (q_x, rachats) qui lui est exclusive et dont l'unique but est d'annuler mécaniquement le biais d'agrégation.

3.4.2.1 Définition des clés d'agrégation financières

Pour que la méthode du *Biais Zéro* fonctionne intégralement, il est nécessaire de garantir une stricte fidélité dans la projection des flux de revalorisation futurs.

Contrairement aux flux de rachats et de décès qui sont linéaires (et peuvent donc être parfaitement lissés par des taux induits), la mécanique de PB est intrinsèquement non linéaire, notamment en raison de la composante optionnelle des garanties financières ($\max(0, Tx_{\text{servi}} - TMG)$). Il est par conséquent mathématiquement impossible d'agréger des contrats aux caractéristiques financières hétérogènes sans créer de biais sur la revalorisation.

La segmentation du portefeuille ne s'effectue donc pas sur l'estimation de flux projetés, mais sur une partition déterministe stricte : on regroupe exclusivement les contrats partageant les mêmes paramètres contractuels générateurs de flux. Le portefeuille est ainsi partitionné selon un triplet de variables (les clés d'agrégation) qui régissent la mécanique de revalorisation :

- **Le TMG net** : Le Taux Minimum Garanti contractuel servi à l'assuré.
- **Le TFGSE** : Le Taux de Frais de Gestion Sur Encours contractuel prélevé par l'assureur.
- **Le TAF** : Le Taux d'Affectation des produits financiers (ou taux de participation aux bénéfices).

Cette segmentation garantit que le *Model Point* possède un seuil de rentabilité brut rigoureusement identique à celui des contrats individuels qui le composent :

$$TMG_{brut} = \frac{TMG_{net} + TFGSE}{TAF} \tag{3.14}$$

3.4.2.2 Mécanique des décréments et modification du cœur ALM

Une fois les contrats regroupés selon leurs clés financières (formant ainsi les groupes C_k), il convient d'annuler l'erreur d'agrégation sur la dimension biométrique et comportementale. Pour estimer les probabilités sur-mesure, il est impératif de faire tourner le modèle ALM une première fois en vision granulaire (contrat par contrat) sur un scénario de base, en mode passif seul (sans interaction avec l'actif ni participation aux bénéfices dynamique).

Cette exécution permet de récupérer les trajectoires exactes des flux de prestations et des bases d'application associées. Il convient de noter que ce calcul préliminaire n'alourdit pas le processus global : la projection des engagements en passif seul est, de toute manière, une étape réglementaire systématique et incontournable pour valider la qualité d'une agrégation sur le *Best Estimate* avant toute projection stochastique complète.

Pour atteindre une erreur nulle, la calibration des lois induites respecte scrupuleusement l'ordonnancement des flux au sein du moteur de projection (développé en Polars). Le moteur appliquant les rachats sur la PM revalorisée à mi-période, et les décès sur la PM nette des rachats, les lois induites $q_{k,t}$ sont calculées sur ces **bases d'application exactes**. Pour un *Model Point* financier k, les probabilités de rachat ($q^{rt}_{k,t}$) et de décès ($q^{dc}_{k,t}$) sont définies par le ratio entre la somme des prestations réelles et la somme des encours exposés au risque :

$$q^{rt}_{k,t} = \frac{\sum_{i \in C_k} PR_{i,t}}{\sum_{i \in C_k} BR_{i,t}} \quad ; \quad q^{dc}_{k,t} = \frac{\sum_{i \in C_k} PD_{i,t}}{\sum_{i \in C_k} BD_{i,t}} \tag{3.15}$$

Où $PR_{i,t}$ et $PD_{i,t}$ représentent respectivement les montants de prestations pour rachats et pour décès projetés en passif seul. Les termes $BR_{i,t}$ et $BD_{i,t}$ désignent les bases d'application exactes à mi-période.

Sur le plan opérationnel, l'implémentation de cette méthode exige une adaptation du cœur du modèle ALM. Le module de vieillissement du passif ne doit plus faire évoluer l'âge ou l'ancienneté pour lire une table réglementaire externe, mais est reprogrammé pour lire et appliquer directement les vecteurs de probabilités de sortie ($q_{k,t}$) pré-calculés, rattachés à chaque *Model Point*. Cette approche, en capturant l'intégralité de la cinétique des flux, permet d'atteindre le *Biais Zéro* opérationnel sur l'ensemble des projections.

3.5 Conclusion

Ce chapitre a permis d'exposer le socle théorique des différentes méthodes d'agrégation envisagées, de la rigidité des approches déterministes classiques à la flexibilité des algorithmes d'apprentissage automatique spatial, jusqu'à la complexité des modèles d'appariement de flux financiers. Chaque méthode présente des compromis distincts entre la précision de la modélisation, le respect des garanties financières et le coût computationnel.

Cependant, l'évaluation purement théorique de ces approches demeure insuffisante pour statuer sur leur applicabilité. Il est désormais impératif de confronter ces méthodes à la réalité d'un moteur de projection stochastique. Le chapitre suivant s'attachera ainsi à définir un protocole de test standardisé et à mener une analyse comparative rigoureuse, afin d'identifier la méthodologie optimale pour l'évaluation des passifs sous le référentiel Solvabilité 2.

Chapitre 4

Protocole d'analyse et résultats de l'agrégation

Ce chapitre constitue le cœur expérimental de cette étude. Après avoir exposé les fondements théoriques des méthodes d'agrégation, il s'agit désormais de mettre en œuvre un cadre rigoureux pour comparer leurs performances. L'objectif est double : quantifier précisément le risque de modèle induit par la réduction de dimension sur le passif seul, puis valide r la robustesse de la méthode sélectionnée à travers des analyses de sensibilité.

4.1 Définition du protocole de test comparatif

La sélection de la méthode d'agrégation optimale ne peut reposer sur une simple intuition statistique. Elle nécessite un cadre expérimental capable de simuler les conditions réell es d'une clôture prudentielle, en mettant en concurrence la simplicité des méthodes déterministes et la puissance des approches par apprentissage.

4.1.1 Constitution des portefeuilles de test

L'étude s'appuie sur un portefeuille de référence, désigné par la suite comme le « Portefeuille Full », composé de **50 000 contrats individuels**. Ce volume a été choisi pou r représenter une taille critique permettant d'observer les phénomènes de compensation statistique tout en restant techniquement projetable en un temps raisonnable pour établir un e base de comparaison exacte.

Chaque contrat est défini par un vecteur de caractéristiques multidimensionnel $\mathbf{x}_i \in \mathbb{R}^{12}$, comprenant notamment :

- **Variables de risques biométriques :** Âge de l'assuré (de 18 à 95 ans) et Sexe.
- **Variables de structure fiscale :** Ancienneté du contrat (cruciale pour les lois de rachat et la fiscalité en cas de décès).
- **Variables financières :** Provision Mathématique (PM), Taux Minimum Garanti (TMG) variant de 0% à 4,5%, et taux de chargement.

Le processus de mise en œuvre suit une architecture en trois étapes distinctes :

1. **Phase de pré-traitement :** Standardisation (z-score) des variables continues et application du *dithering* pour les méthodes de densité afin de fluidifier l'espace des données discrétisées.
2. **Génération des Model Points :** Application de chaque algorithme cible pour obtenir des portefeuilles compressés. Pour chaque méthode, nous avons fait varier les hyperparamètres afin de générer une famille de portefeuilles allant de 25 à 5 000 lignes.
3. **Projection ALM Massive :** Chaque portefeuille compressé est injecté dans le moteur de projection complet (projection sur 50 ans, scénario central Best Estimate) pour mesurer l'impact réel sur les flux.

[GRAPHIQUE : Workflow du Protocole de Test]
Schéma montrant le flux : Portefeuille Initial → Clustering → Vecteurs de flux → Moteur ALM → Comparaison BE

FIGURE 4.1 – Schéma de mise en œuvre du protocole de test comparatif

4.1.2 Définition des critères de sélection

Le choix final de la méthode repose sur un arbitrage multicritère, principalement axé sur la recherche d'un point optimal sur la « Courbe de Pareto » entre précision et taux de co mpression.

— **La fidélité sur le Best Estimate (BE) :** Mesurée par l'erreur relative $\Delta_{BE}\%$. Une erreur supérieure à $0,05\%$ est considérée comme significative.

$$\Delta_{BE}\% = \frac{BE_{agrégé} - BE_{référence}}{BE_{référence}} \tag{4.1}$$

— **La préservation de la "Pureté Financière" :** Capacité de la méthode à ne pas diluer les taux garantis (TMG) au sein des groupes.

— **Le taux de compression :** On cherche à descendre en dessous de 1 000 Model Points pour garantir la fluidité des calculs stochastiques futurs.

— **Le temps de constitution (Overhead) :** Le coût de préparation des données doit rester marginal par rapport au gain de temps de projection.

4.2 Analyse comparative et choix de la méthode optimale

4.2.1 Synthèse des performances sur le passif seul

L'analyse massive réalisée (plus de 150 simulations individuelles) a permis de dresser une matrice de performance exhaustive permettant d'isoler le comportement de chaque algorith me face à la compression.

Méthode	Variante / Paramètres	Nb MP	Erreur BE %	Écart (M€)	Robustesse
Référence	*Portefeuille 50k lignes*	*50 000*	*0,000 %*	*0,0*	*Absolue*
Biais Zéro	**Triplet (TMG, TFG, TAF)**	**1 105**	**0,006 %**	**0,8**	**Optimale**
Biais Zéro	**Compression massive**	**2 060**	**-0,005 %**	**-0,7**	**Excellente**
Banding	Smart Fiscal (Anc 8 ans)	1 253	0,0018 %	0,2	Très stable
K-Means	Pondéré PM (n=1000)	999	0,0021 %	0,3	Constante
HDBSCAN	Selection : Leaf (Fin)	1 013	0,0026 %	0,3	Très sensible
Banding	Classique (Age 5, Anc 5)	483	0,0024 %	0,3	Stable
CART	Refined (Target PM/TMG)	999	-0,1081 %	-13,5	Biaisée
CART	Spread Focus (TMG Only)	26	0,1319 %	16,5	Grossière

TABLE 4.1 – Matrice comparative des performances d'agrégation sur le Best Estimate

[GRAPHIQUE : Courbe de Pareto Précision/Compression]
Axes : X = Nb Model Points (log), Y = Erreur BE % (log).
Courbes pour : Banding, K-Means, Biais Zéro.

FIGURE 4.2 – Arbitrage Précision vs Nombre de Model Points par méthode

Plusieurs enseignements majeurs découlent de ces résultats :

1. **La neutralisation du biais par calibration :** La méthode « Biais Zéro » surpasse toutes les autres en termes de fidélité pure. En calibrant les probabilités de sortie sur les bases réelles à mi-période, l'agrégation devient quasiment transparente pour le calcul du Best Estimate.
2. **L'importance du triplet financier :** Les tests ont montré que le respect strict des clés $(TMG, TFGSE, TAF)$ est indispensable. Une agrégation ignorant les frais de gestion (TFGSE) génère un biais résiduel de plus de 2%, quel que soit le protocole de calibration.

3. **L'efficacité du Banding Fiscal :** Le découpage métier autour de l'ancienneté de 8 ans reste une alternative très performante pour les méthodes déterministes.
4. **Le biais des approches CART :** Bien que très compressives, les méthodes par arbres de décision introduisent des ruptures artificielles dans la structure de revalorisation, nuisant Ã la précision globale.

4.2.2 Justification du choix de la méthode retenue

4.3 A faire

Ce chapitre contiendra la méthodologie utilisée pour comparer les différentes méthodes d'agrégation. Notre critère de sélection sera la capicité à réduire le nombre de model point X limiter l'écart sur les BE centraux et choqués (cad les SCR). Pour comparer les résultats, on va prendre comme base de reference le portefeuille aggrégé avec la méthode standard par caractérique pure. En théorie, cette méthode ne génère aucun écart ni biais de regroupement sur le BE passif seul. Ce qui est vérifié. Pour la suite ce sera alors la base de comparaison car plus simple à éxecuter et plus rapide que le portefeuille full. Ensuite on va calibrer tous les modèles qui doivent être calibrer et montrer comment la calibration joue un rôle crucial pour réduire les biais de regroupement. Enfin on va présenter une matrice de résultats avec les différentes méthodes et différentes configurations (nombre de model point, critères d'agrégation, etc) et montrer que la méthode retenue est celle qui offre le meilleur compromis entre précision et taux de compression. ce qui fera plusieurs parties. donc dans l'ordre 1 - Présentation du protocole de test comparatif (portefeuille de référence, critères de sélection, etc) 2 - calibration des méthodes qui nécessitent une calibration et démonstration de l'impact de la calibration sur la réduction du biais de regroupement 3 - Présentation de la matrice de résultats (passif seul, passif seul choqué, alm central puis alm sto choqués) et justification du choix de la méthode retenue

Au terme de cette analyse, la méthode **Calibration a posteriori (Biais Zéro)** est retenue pour la suite de ce mémoire. Elle offre le niveau de précision requis pour des analyses de sensibilité fines, garantissant que les variations de Best Estimate mesurées seront exclusivement dues aux chocs appliqués et non à un bruit de regroupement résiduel.

Chapitre 5

Conclusion

5.1 Résumé des résultats

5.1.1 Synthèse des principaux résultats obtenus

5.1.2 Impact des méthodes d'agrégation sur les portefeuilles de passifs

5.2 Perspectives d'amélioration

5.2.1 Axes d'amélioration pour les générateurs de portefeuilles de passifs

5.2.2 Évolutions possibles des méthodes d'agrégation et de modélisation ALM

5.2.3 Autres domaines d'application des générateurs de portefeuilles de passifs

5.3 Conclusion Générale et Perspectives

Annexes

Chapitre 2

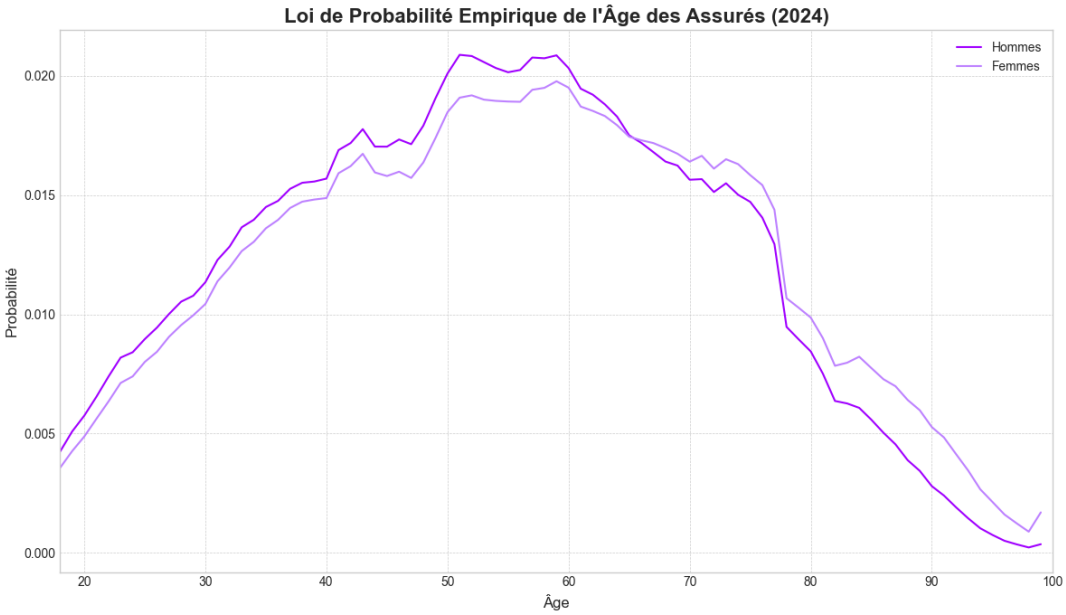

FIGURE 5.1 – Distribution empirique de l'âge des assurés (Hommes et Femmes).

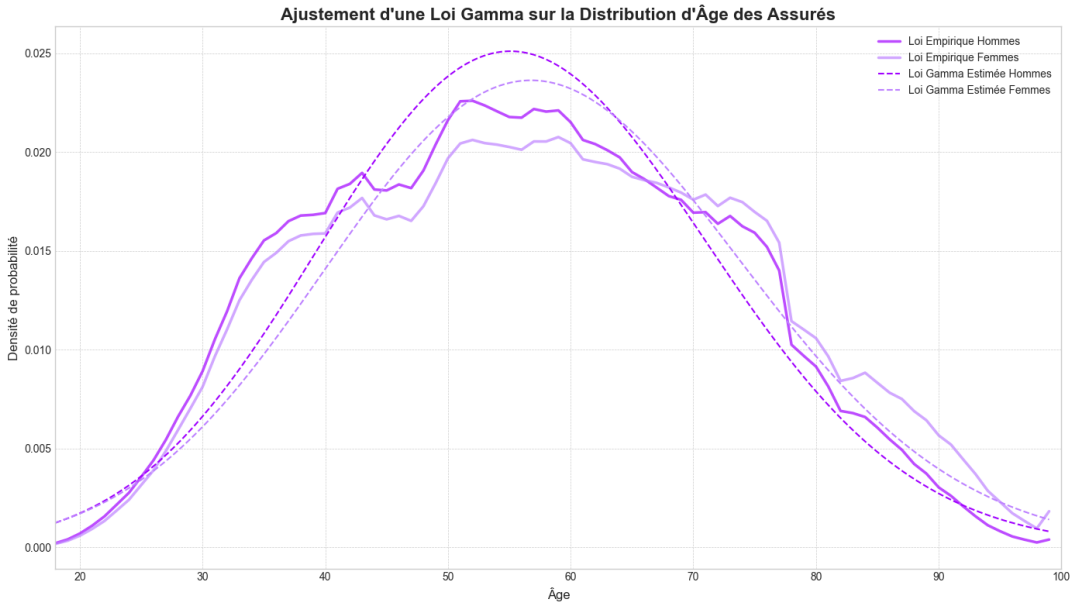

FIGURE 5.2 – Ajustement de la loi Gamma sur la distribution empirique.

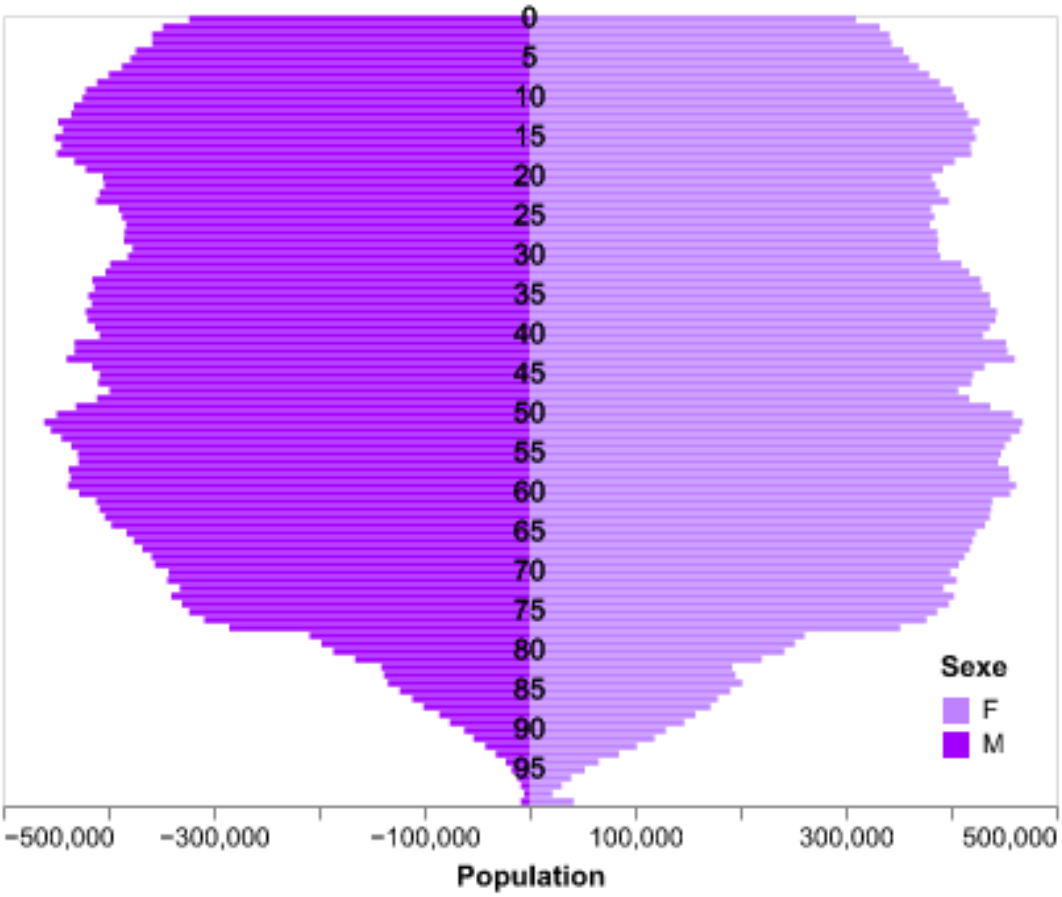

FIGURE 5.3 – Pyramide des âges de la population française en 2024 [7].

TABLE 5.1 – Historique du taux technique maximal et du TMG utilisé dans le modèle (1993–2024)

Année	$TT_t^{\max}$ (taux technique max)	TMG_t (taux min. garanti retenu)
1993	0,045	0,045
1994	0,045	0,045
1995	0,035	0,035
1996	0,035	0,035
1997	0,0339	0,0325
1998	0,0272	0,025
1999	0,0265	0,025
2000	0,0329	0,0325
2001	0,0301	0,030
2002	0,0292	0,0275
2003	0,0247	0,0225
2004	0,0243	0,0225
2005	0,0207	0,020
2006	0,0229	0,0225
2007	0,0260	0,025
2008	0,0261	0,025
2009	0,0219	0,020
2010	0,0189	0,0175
2011	0,0213	0,020
2012	0,0153	0,015
2013	0,0141	0,0125
2014	0,0099	0,0075
2015	0,0051	0,0000
2016	0,0027	0,0000
2017	0,0045	0,0000
2018	0,0048	0,0000
2019	0,0009	0,0000
2020	0,0000	0,0000
2021	0,0003	0,0000
2022	0,0090	0,0000
2023	0,0186	0,0000
2024	0,0180	0,0000

Calibration initiale du modèle d'allocation (Inclusion de l'ancienneté)

Lors de la phase de spécification du modèle Logit visant à répartir la Provision Mathématique entre le fonds en euros et les unités de compte, une troisième variable explicative avait été initialement retenue : l'ancienneté du contrat (Anciennete_i). L'objectif était de capter un effet générationnel, l'hypothèse économique sous-jacente étant que les contrats les plus anciens (souscrits dans un contexte de taux garantis élevés) étaient structurellement plus orientés vers le fonds en euros. Le prédicteur linéaire s'écrivait alors :

$$\eta_i = \beta_0 + \beta_{\text{age}}\,\text{Age}_i + \beta_{\text{pm}}\,\log(\text{PM}_i) + \beta_{\text{anc}}\,\text{Anciennete}_i$$

Cependant, la calibration par *matching de moments* sur les profils de contrôle a abouti aux coefficients suivants : $\beta_0 = 1.0039$, $\beta_{\text{age}} = -0.0424$, $\beta_{\text{pm}} = 0.0746$ et $\beta_{\text{anc}} = 0.0008$.

Outre sa valeur quasi nulle traduisant un pouvoir explicatif marginal, le signe positif du coefficient β_{anc} contredisait l'intuition économique de départ. Ce résultat s'explique par une forte colinéarité entre l'âge de l'assuré et l'ancienneté de son contrat. L'algorithme d'optimisation a par conséquent transféré l'essentiel du poids explicatif sur la variable d'âge, rendant l'ancienneté redondante. Par souci de robustesse et pour éviter tout sur-paramétrage (*overfitting*), cette variable a donc été retirée du modèle final présenté dans le corps du mémoire.

Bibliographie

[1] FRANCE ASSUREURS. *L'assurance vie en 2024.* (23 septembre 2025). Consulté le 28 Octobre 2025, sur https://www.franceassureurs.fr/nos-chiffres-cles/assurance-vie/lassurance-vie-en-2024/

[2] ACPR. *Notice sur les modèles internes.* (2023). Consulté le 17 Février 2026, sur https://acpr.banque-france.fr/system/files/import/acpr/media/2023/12/01/20231201_notice_mi_s2.pdf

[3] DORNAIKA Fadi, HAMAD Denis, CONSTANTIN Joseph, TRONG HOANG Vinh. *Advances in Data Clustering.* Lieu d'édition : Springer, 2024.

[4] GOFFARD Pierre-Olivier, GUERRAULT Xavier. « Is it optimal to group policyholders by age, gender, and seniority for BEL computations based on model points ? ». *European Actuariel Journal*, volume 5, 17 Avril 2015, p. 165-180.

[5] BEN FADHEL Amine. « Accéleration de l'évaluation de la solvabilité prospective d'un assureur épargne ». *Mémoire pour l'Institut des Actuaires* , 2022.

[6] INSEE. *Taux de détention des produits de patrimoine selon l'âge de la personne de référence du ménage en 2021.* (2021). Consulté le 18 Septembre 2025, sur https://www.insee.fr/fr/outil-interactif/5367857/details/30_RPC/34_PAT/34A_Figure1

[7] INSEE. *Pyramide des âges de la population française en 2024.* (2024). Consulté le 1er Septembre 2025, sur https://www.insee.fr/fr/outil-interactif/5014911/pyramide.htm

[8] INSEE. *Enquête Histoire de vie et Patrimoine 2020-2021.* 2021. Consulté le 24 Janvier 2026, sur https://www.insee.fr/fr/statistiques/7941419?sommaire=7941491#tableau-figure1

[9] IFOP. *Enquête sur les 60 ans de l'indépendance financière des femmes : chiffres clés sur la répartition hommes-femmes en assurance vie.* (16 Juillet 2025). Consulté le 16 Novembre 2025, sur https://www.ifop.com/article/enquete-sur-les-60-ans-de-lindependance-financiere-des-femmes/

[10] IFOP. *Baromètre - les femmes et l'argent : chiffres clés sur la répartition hommes-femmes sur les fonds EURO et UC en assurance vie.* (Janvier 2024). Consulté le 16 Novembre 2025, sur https://www.ifop.com/wp-content/uploads/2024/03/barometre-vives-2024ok-1.pdf

[11] geeksforgeeks. *K-Means vs K-Means++ Clustering Algorithm.* Consulté le 1 Février 2026, sur https://www.geeksforgeeks.org/machine-learning/k-means-vs-k-means-clustering-algorithm/

[12] Daily Dose of Data Science. *HDBSCAN vs. DBSCAN.* Consulté le 1 Février 2026, sur https://blog.dailydoseofds.com/p/hdbscan-vs-dbscan

[13] HDBSCAN Developers. *How HDBSCAN Works*. Consulté le 3 Février 2026, sur `https://hdbscan.readthedocs.io/en/latest/how_hdbscan_works.html`

[14] ACPR. *Le taux technique en assurance vie (Code des assurances)*. Consulté le 14 Février 2026, sur `https://acpr.banque-france.fr/sites/default/files/medias/documents/201606_as66_le_taux_technique_en_assurance_vie.pdf`

[15] ACPR. *Assurance vie en France et environnement de taux bas*. Consulté le 14 Février 2026, sur `https://acpr.banque-france.fr/sites/default/files/medias/documents/201705-as78-taux-bas-version-3_0.pdf`

[16] ACPR. *Revalorisation 2024 des contrats d'assurance-vie et de capitalisation*. Consulté le 14 Février 2026, sur `https://acpr.banque-france.fr/fr/publications-et-statistiques/publications/ndeg-175-revalorisation-2024-des-contrats-dassurance-vie-et-de-capitalisation`

[17] ACPR. *Le marché de l'assurance-vie en 2024*. Consulté le 14 Février 2026, sur `https://acpr.banque-france.fr/fr/publications-et-statistiques/publications/ndeg-170-le-marche-de-lassurance-vie-en-2024`

[18] Good Value for Money. *Taux Minimum Garanti (TMG)*. Consulté le 14 Février 2026, sur `https://www.goodvalueformoney.eu/documentation/taux-minimum-garanti-tag`

[19] France Assureurs. *L'assurance vie en unités de compte en 2024*. Consulté le 14 Février 2026, sur `https://www.franceassureurs.fr/nos-chiffres-cles/assurance-vie/lassurance-vie-en-unites-de-compte-en-2024/`

[20] La Banque Postale. *Contrat La Banque Postale : Cachemire 2 Série 2*. Consulté le 6 Mars 2026, sur `https://www.labanquepostale.fr/particulier/epargner/assurance-vie-et-solution-retraite/cachemire-2.html`

[21] INSEE. *Indice de Gini : Revenu, niveau de vie et pauvreté en 2018* . Consulté le 12 Mars 2026, sur `https://shorturl.at/zTERw`